



**Tecnológico
de Monterrey**

01. Presentación del curso

Ciencia de Datos II

Introducción al curso y fundamentos de los LLMs
10 de agosto de 2026

**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

Sobre mí



M.C. JORGE JUVENAL CAMPOS FERREIRA.

- * **Analista de datos, México, ¿Cómo vamos? Y Fundación Novagob México**
- * **Columnista en Atiempo.TV Coahuila**

Educación Formal:



Licenciatura:

Ingeniería en Irrigación por la Universidad Autónoma Chapingo. (2009-2014).



Maestría:

Maestría en Economía por El Colegio de México (2016-2018).

Contacto:



GitHub: JuveCampos



LinkedIn: Jorge Juvenal Campos Ferreira



Twitter: @JuvenalCamposF



IG: juvenalcampos.dataviz



<https://juvenalcampos.com/>

Qué vamos a lograr este semestre

Propósito del curso

Que **el estudiante diseñe, implemente y comunique soluciones de ciencia de datos de forma integral: programación en R, IA generativa, bases de datos, procesamiento de texto y análisis de lenguaje natural**, orientados a la toma de decisiones basadas en evidencia.

La apuesta de esta edición

A diferencia de años anteriores, **en esta edición se plantea introducir un módulo de uso de herramientas de Inteligencia Artificial generativa**, con el objetivo de que aprendan los conceptos básicos, a usar y dirigir la IA, verificar sus resultados y documentar su proceso.



El calendario del curso

PMT1 · 10 ago – 10 sep · L, Mi, J · 9–11

PMT2 · 21 sep – 22 oct · L, Mi, J · 9–11

...

PMT3 · 2 nov – 3 dic · L, J · 9–11 (sin 16 nov)

Agosto 2026

L	M	Mi	J	V	S	D
					1	2
3	4	5	6	7	8	9
10	11	12	13	14	15	16
17	18	19	20	21	22	23
24	25	26	27	28	29	30
31						

Septiembre 2026

L	M	Mi	J	V	S	D
	1	2	3	4	5	6
7	8	9	10	11	12	13
14	15	Semana TEC 1			19	20
21	22	23	24	25	26	27
28	29	30				

Octubre 2026

L	M	Mi	J	V	S	D
			1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	Semana TEC 2			31	

Noviembre 2026

L	M	Mi	J	V	S	D
						1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30						

Diciembre 2026


L	M	Mi	J	V	S	D
	1	2	3	4	5	6
7	8	9	10	11	12	13
14	15	16	17	18	19	20
21	22	23	24	25	26	27
28	29	30	31			

39 sesiones divididas en
tres periodos (los dos primeros con 3
clases, el último con 2)

El temario del curso

Bloque 1 - Herramientas de IA

Fundamentos de LLMs, prompting, vibe-coding, multimodal, scraping y APIs. (agosto-septiembre)



Bloque 2 - Bases de datos

Uso de bases de datos. (septiembre-octubre)



Bloque 3 - Manejo de texto

stringr, expresiones regulares, tokenización y limpieza de corpus. (octubre)



Bloque 4 - PLN y análisis

TF-IDF, embeddings, tópicos, sentimientos y visualización. (noviembre)



Reto con socio formador (noviembre-diciembre)

Un modelo que resuelva un problema real a partir de textos. Se presenta el 14 de octubre y se entrega el 3 de diciembre.

Temario

Bloque 1. Herramientas de inteligencia artificial generativa

- 1.1 Fundamentos de los modelos de lenguaje
- 1.2 Anatomía de un modelo de lenguaje
- 1.3 Capacidades y límites
- 1.4 Ética, sociedad y mercado laboral
- 1.5 Propiedad intelectual y política pública
- 1.6 Diseño de instrucciones (prompting)
- 1.7 Asistentes de código y programación asistida
- 1.8 Generación multimodal
- 1.9 Datos abiertos y descarga automatizada
- 1.10 Raspado web (*Web scraping*)
- 1.11 Interfaces de programación y conexión con datos externos

Temario

Bloque 2. Bases de datos y arquitectura

2.1 Diseño y modelado de datos

2.2 Consulta con SQL

2.3 Bases no relacionales y arquitectura moderna

Bloque 3. Manejo y limpieza de datos de texto

3.1 Fundamentos del dato textual

3.2 Manipulación de cadenas (strings) en R

3.3 Expresiones regulares (regex)

3.4 Tokenización y conteo

3.5 Limpieza de corpus

Temario

Bloque 4. Procesamiento de lenguaje natural y análisis de texto

- 4.1** La fijación de agenda como pregunta de investigación
- 4.2** Representación del texto y aprendizaje supervisado
- 4.3** Embeddings
- 4.4** Modelado de tópicos
- 4.5** Análisis de polaridad y sentimiento
- 4.6** Visualización y comunicación de resultados

Proporción del contenido



Juvenal Campos

62% del curso (24 sesiones)


Aplicaciones de IA, Repaso de R, Manejo de texto.



José Manuel Toral

25% del curso (10 sesiones)

Aplicaciones de IA, PNL, Bases de datos. Encargado del reto.



Bogdan Popescu

13% del curso (5 sesiones)

Repaso de R, econometría, análisis de datos.

Sobre el reto

Durante este semestre, trabajaremos en colaboración con Global Fund for Women en un reto enfocado en el uso de ciencia de datos para potenciar su misión de financiar y fortalecer movimientos sociales alrededor del mundo.

El desafío consistirá en desarrollar un modelo que tome como insumo principal texto — por ejemplo, documentos, narrativas o descripciones de proyectos — y que pueda aportar valor a la organización en la identificación, clasificación o análisis de información relevante para sus objetivos estratégicos. Este modelo podrá ser supervisado o no supervisado, según la naturaleza del problema planteado y la estrategia de abordaje del equipo.


Contaremos con la Dra. María de los Ángeles Lasa, Gerente del Data Gender Hub, como socia formadora, quien nos guiará para asegurar que la solución propuesta esté alineada con las necesidades reales y el impacto social que busca la organización.



Evaluación

Propuesta de evaluación*:

- **Tareas:** 20% de la calificación total
- **Exámenes:** 30% de la calificación total
- **Reto:** 50% de la calificación total



Este semestre priorizaremos la evaluación de tareas a través de mecanismos tradicionales (exposiciones, material escrito a mano, entrevistas).

Igualmente, se nos solicita que uno de los exámenes aplicados sea a mano y en papel (iremos pensando en cual).

***En caso de haber cambios, se les avisará con anticipación**

Reglas de la clase

En el salón

- * Respeto total a compañeros y profesores.
- * Participación ordenada.
- * Dispositivos electrónicos solo para actividades del curso.
- * Mas las reglas de convivencia básicas del semestre anterior.
- * Estar presentes en el pase de lista
- * Traer libreta y bolígrafos de colores para tomar apuntes).

Ojo: Por favor, respeten las reglas de cada profesor, ya que cada profesor tiene sus propias reglas.



Sobre trabajos y tareas

- * Entregar tareas y trabajos en tiempo y forma
- * Contestar todas las preguntas y ejercicios marcados en la tarea
- * Seguir las normas de integridad académica y uso de la IA del Tec de Monterrey



Tipos de tareas



Uso de IA

Tareas y ejercicios hechos para que practiquen el uso de la Inteligencia Artificial generativa. En estos ejercicios se espera que la IA haga una gran parte del trabajo, donde el aprendizaje del estudiante estará en desarrollar su habilidad de usarla para obtener resultados óptimos y deseables. Los entregables serán proyectos complejos que de otra manera demandarían muchas horas de capacitación y trabajo para ser desarrollados.



Apoyo de IA

Tareas y ejercicios en los que la persona se apoya de la IA, mas no le delega todo el trabajo. En estos trabajos se usará la IA como asistente, sin sustituir todo el trabajo o el criterio humanos.



Sin IA

En estos ejercicios y tareas se solicitará no usar IA. Esta categoría será para la parte de generación de código de los últimos meses del semestre (NLP, manejo de texto) y tienen como objetivo desarrollar habilidades y comprender conceptos. Para el cumplimiento, se penalizarán ciertos comportamientos o características descritos en las rúbricas de cada entregable.

Recursos



Repositorio de Github del curso:

<https://github.com/JuveCampos/TC2002B.651-Ciencia-de-datos-II-Agosto-Diciembre-2026>

(Mis diapositivas, código y ejercicios se subirán acá de la misma manera que en el curso anterior, así como en el Canvas).

Lecturas y cursos recomendados:

1. James G., Witten D., Hastie T., Tibshirami R., 2013. An Introduction to Statistical Learning with applications in R. Springer.
2. Hastie T., Tibshirami R., Friedman J., 2009. The elements of statistical learning. Second Edition.
3. Jurafsky D., Martin J., 2026. Speech and Language Processing (3rd ed. draft). Stanford.
4. Anthropic courses: <https://anthropic.skilljar.com>
5. OpenAI academy: <https://openai.com/es-419/academy/codex/>
6. String manipulation with stringr in R, a Datacamp Course: <https://app.datacamp.com/search?q=stringr>



Vayan armando equipos para esta primera parte

Armar equipos (de hasta el número de integrantes de los equipos del reto anterior) para las tareas de la primera parte.

Ustedes determinen el número e integrantes.

Pueden hacer las tareas y los ejercicios de manera individual.



¿Dudas?



Tema 1

¿Cómo funcionan los LLMs?

Introducción a los Modelos de Lenguaje

Un sistema de IA que **procesa y genera texto** en lenguaje natural, aprendiendo patrones a partir de **grandes** cantidades de datos.

Ejemplo: Predecir la palabra que sigue en una frase.



El modelo predice el siguiente token una y otra vez, a partir de patrones aprendidos en cantidades enormes de texto.

Definiciones de trabajo

★ Modelo grande de lenguaje (LLM - Large Language Model)

Un modelo grande de lenguaje (LLM) es un **sistema de IA** que procesa y genera lenguaje natural aprendiendo patrones de cantidades enormes de texto. Su tarea básica es predecir el siguiente token. De esa tarea simple emergen tareas como traducción, resumen, código y razonamiento.

★ Inteligencia Artificial

Inteligencia artificial es el campo de la computación dedicado a construir sistemas capaces de realizar tareas que, cuando las hace un humano, asociamos con inteligencia: percibir, razonar, aprender, decidir y/o comunicarse.

La IA es el estudio y diseño de **agentes computacionales** que perciben su entorno y toman acciones para maximizar sus probabilidades de alcanzar un objetivo. (*Russell y Norvig, Artificial Intelligence: A Modern Approach*).

★ Agente computacional

Sistema que percibe su entorno a través de sensores y actúa sobre él mediante actuadores, siguiendo una política que traduce lo percibido en acciones orientadas a un objetivo. Lo que define al agente no es su mecanismo interno (reglas explícitas, modelos estadísticos o redes neuronales), sino la relación **percepción-acción** que mantiene con su entorno.

¿Cómo funciona un LLM?

1.Revisar video:

<https://www.youtube.com/watch?v=awGfhmsN7Lc>



Los dos procesos involucrados en un LLM:

Entrenamiento

Proceso que ocurre una vez, en centros de datos.

Miles de GPUs durante meses; costos de decenas o cientos de millones de USD.

Ahí el modelo 'aprende' los patrones del lenguaje.

Inferencia

Proceso que ocurre cada vez que ustedes escriben un prompt.

Se cobra por token procesado y generado.

El modelo ya no aprende: solo aplica lo aprendido. Por eso existe el corte de conocimiento.

Idea clave


Cuando chateamos con un modelo no lo estamos 'entrenando' en vivo: consumimos inferencia. Esta distinción explica costos, cortes de conocimiento y por qué el modelo no recuerda entre sesiones.

Los dos procesos involucrados en un LLM:


ENTRENAMIENTO

Aprender una nueva capacidad a partir de datos existentes


Modelo de Red Neuronal No Entrenado



Marco de Aprendizaje Profundo




Modelo Entrenado Nueva Capacidad



INFERENCIA

Aplicar esta capacidad a nuevos datos

Aplicación o Servicio Con Capacidad de Predicción



Modelo Entrenado Optimizado para Rendimiento

<https://www.naddod.com/es/ai-insights/training-vs-inference-why-your-ai-network-architecture-needs-to-be-different?srsId=AfmBOoMQV6ZYV-b0CMUowMIpO4YnceOpO3y1NdOXZdWxwYqqSZTkag>

¿Cuáles son mejores?

Artificial Analysis Intelligence Index: Score

Independently benchmarked by Artificial Analysis



28 of 582 models




NEW



Add model from specific provider

Artificial Analysis




💡 Reasoning models are indicated by a lightbulb icon

<https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index>

Historia de los LLMs desde ChatGPT


Cuatro años que cambiaron a la industria



Fuente: Wikipedia y anuncios oficiales de cada laboratorio. Corte: agosto de 2026.

ChatGPT rompió todos los récords de adopción

Ningún producto de consumo había crecido tan rápido



30 de noviembre de 2022

GPT-3.5 + RLHF (ajuste con retroalimentación humana).

Gratuito y conversacional: la IA dejó de ser tema de laboratorio y se volvió consumo masivo.

2023-2024: la competencia se organiza

GPT-4 (mar 2023)

Multimodal, aprueba exámenes profesionales; GPT-4o (2024) responde en tiempo real con voz e imagen.

Claude (mar 2023)


Apuesta por contextos largos: 100k tokens en 2023, 200k en 2024. Introduce Artifacts.

Gemini (dic 2023)

Google entra con fuerza; Gemini 1.5 lleva el contexto a 1 millón de tokens (2024).

Llama (2023-2024)

Meta libera pesos abiertos: cualquiera puede descargar y ejecutar el modelo. Nace el ecosistema abierto.



2024: los modelos aprenden a 'pensar' antes de responder

Modelos de razonamiento (o1, septiembre de 2024)

Idea central: cómputo en tiempo de inferencia. El modelo genera una cadena de razonamiento interna antes de contestar. Más lento y más caro, pero mucho mejor en matemáticas, ciencia y código.

El salto medible

En el examen de matemáticas AIME: o1-preview logró 83% frente a 13% de GPT-4o.

Por qué les importa

Hoy casi todos los modelos punteros ofrecen 'esfuerzo de razonamiento' ajustable: más pensamiento cuesta más tokens.

Enero de 2025: DeepSeek sacude los mercados



~\$5.6 millones USD

costo de entrenamiento reportado de DeepSeek-V3, frente a ~\$100 millones reportados para GPT-4.

Licencia MIT

R1 liberó código y pesos abiertos: razonamiento de frontera para cualquiera.

-18% Nvidia en un día

~\$600 mil millones USD de capitalización perdidos: la mayor caída de una empresa en la historia bursátil de EUA.

Lección: la eficiencia también es una frontera de investigación, no solo el tamaño.

<https://juvenalcampos.com/posts/2025-02-11-ia-2025/>

2025: de chatbots a agentes que usan herramientas

Computer use (oct 2024)

El modelo mira la pantalla, mueve el cursor y hace clic: primeros agentes de escritorio.

Claude Code (2025)

Asistentes que leen y escriben archivos, corren código y verifican resultados en la terminal.

MCP (nov 2024)

Protocolo abierto para conectar modelos con datos y herramientas; lo adoptaron OpenAI, Google y Microsoft en 2025.

¿Por qué importa?

El flujo de trabajo del curso (vibe-coding) existe gracias a esta capa de agentes y conectores.

2026: la frontera hoy se llama clase Mythos

Claude Fable 5 y Mythos 5 (junio de 2026)

Nueva clase de modelos por encima de Opus: migraciones de código a gran escala, contexto de millones de tokens, razonamiento financiero y aplicaciones en biología molecular. Fable 5 es la versión de uso general con salvaguardas.

El resto de la frontera

OpenAI: GPT-5.6 (Sol, Terra, Luna).

Google: Gemini 3.1 y 3.6.

Abiertos: DeepSeek V4, Qwen, GLM, Kimi K3.

Anthropic: Opus 5 (julio de 2026).

Lo que deben retener

Los nombres cambian cada semestre; los conceptos no: tokens, contexto, razonamiento, agentes y costo. Eso es lo que este bloque les deja.

¿Con cuál trabajo? Los cuatro asistentes del curso

ChatGPT (OpenAI)

El ecosistema más maduro y popular. Gratis / \$20 USD.

Claude (Anthropic)


Contexto de 1M de tokens y fuerte en código. Gratis / \$20 USD.

Gemini (Google)

Integrado con el ecosistema Google. Gratis / \$20 USD.

DeepSeek y modelos chinos

Relación rendimiento/costo imbatible; pesos abiertos.



Para el curso: cuenta gratuita de al menos dos de ellos. Tratar de tener al menos uno de pago.

Conclusiones de la clase 1

Lo que se llevan hoy

1. En este curso trabajaremos de la mano con IA generativa, lo que implica que tengamos orden, metodología, registros y que conozcamos los pros y contras de su uso.
2. Un LLM genera texto prediciendo el siguiente token; usarlo es inferencia, no entrenamiento.
3. En cuatro años pasamos de ChatGPT a agentes que usan herramientas y a la clase Mythos.
4. Los nombres de modelos caducan; los conceptos (tokens, contexto, razonamiento, costo) permanecen.
5. La evaluación premia proyectos, exposiciones y videos: dos terceras partes de la calificación.

Recursos para profundizar

Documento del curso: Historia de los LLMs (Canvas), con todas las fuentes verificadas.

Jurafsky, D. y Martin, J. (2026). Speech and Language Processing, 3a ed. (borrador): web.stanford.edu/~jurafsky/slp3/

Cursos de Anthropic: anthropic.skilljar.com

AI Index Report 2025, Stanford HAI: hai.stanford.edu/ai-index

Video introductorio: 'Intro to Large Language Models' de Andrej Karpathy (YouTube).

Gracias

¿Preguntas?