



Tecnológico
de Monterrey

02. Conceptos LLM

Ciencia de Datos II

Tokens, contexto, temperatura y lo que cuesta usarlos
12 de agosto de 2026

**Jorge
Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

¿Cómo funciona un LLM?

1.Revisar video:

<https://www.youtube.com/watch?v=awGfhmsN7Lc>



¿Cómo funciona un LLM?




Conceptos vistos:

- *Modelos de predicción
- *Tokens y tokenización
- *Corpus de entrenamiento
- *Vectores y espacios multidimensionales
- *Embeddings
- *Redes neuronales
- *Parámetros y pesos
- *Entrenamiento y prueba
- *Mecanismo de atención
- *Temperatura y no determinismo
- *GPT (Generative Pre-trained Transformer)
- *RLHF (aprendizaje por refuerzo con retroalimentación humana)


Los modelos no leen palabras: leen *tokens*



Español: 10 tokens



Inglés: 5 tokens (mismo contenido)



Regla rápida

- * Para los LLMs, 1 token equivale a aproximadamente unos 4 caracteres o 0.75 palabras en inglés.
- * Cada modelo trae su propio tokenizador, y esa decisión de diseño determina cuántos tokens puede gastar el mismo texto.

Medir *tokens* en R:


```
install.packages("rtiktoken")
library(rtiktoken)

texto <- "La inflación general anual se ubicó en 4.2% en julio."
get_token_count(texto, "gpt-4o")
# También puedes ver los tokens mismos:
get_tokens(texto, "gpt-4o")
```



```
> library(rtiktoken)
>
> texto <- "La inflación general anual se ubicó en 4.2% en julio."
>
> # Obtener tokens
> get_token_count(texto, "gpt-4o")
[1] 16
> get_token_count(texto, "gpt-4")
[1] 19
> # También puedes ver los tokens mismos:
> tokens_ejemplo <- get_tokens(texto, "gpt-4o")
> get_tokens(texto, "gpt-4")
[1] 8921 4704 5840 4689 459 940 513 63874 1832 665 220 19 13
[14] 17 4 665 41638 822 13
>
> sapply(tokens_ejemplo, function(x){ decode_tokens(x, "gpt-4o")})
[1] "La" " inflación" " general" " anual" " se" " ubic"
[7] "ó" " en" " " "4" "." "2"
[13] "%" " en" " julio" "."
```

¿Como ingresan dinero las empresas de IA?



Los dos componentes del cobro: *tokens* de entrada y salida


Tokens de entrada

Todo el prompt que se envía: instrucciones, contexto, documentos adjuntos, historial de la conversación.

Tokens de salida (los caros)


Lo que el modelo genera, incluidos los tokens de razonamiento que no vemos. Cuestan de 2 a 6 veces más que los de entrada (5x en Anthropic).

Entre el modelo más barato y el más caro hay ~57 veces de diferencia



Embeddings: cuando el significado se vuelve geometría

Embeddings: palabras con significados parecidos quedan cerca en el espacio



La intuición

Cada *token* se representa como un vector de miles de números.

Palabras usadas en contextos parecidos terminan cerca.

La cercanía se puede medir; eso habilita buscar por significado.

Gato 🐱  Modelo de embeddings **bge-m3**


```
-1.018424e-02 2.623098e-02 -1.483188e-02 -9.407892e-04 -9.367332e-03
-6.104474e-02 -4.593270e-02 3.334625e-02 -3.259182e-02 1.445268e-02
3.067109e-02 1.940103e-02 -3.996122e-02 -3.799319e-03 4.570663e-04
-2.281075e-03 2.740753e-04 1.041945e-02 4.070590e-02 -9.250407e-03
-2.217363e-02 -3.679488e-02 -3.550843e-03 -3.693182e-02 3.846383e-03
3.968254e-04 -5.262867e-04 -2.700280e-02 -1.520473e-03 2.984057e-04
-5.641823e-03 9.427610e-03 5.980298e-03 -6.313990e-02 -6.349202e-02
-2.569284e-02 -6.834993e-03 -1.623306e-02 -5.234681e-02 6.847703e-03
3.615050e-02 4.965418e-03 4.809118e-02 -2.982642e-02 -1.282764e-02
-2.156890e-02 -3.645908e-02 -3.476779e-02 -5.049063e-03 -4.538276e-03
-1.001652e-02 7.311513e-03 2.735134e-02 -2.268461e-02 3.629034e-02
5.327683e-02 -2.719249e-02 -5.618023e-02 -7.675282e-02 3.267734e-03
-2.029226e-02 -2.464433e-03 -4.863346e-02 -5.129919e-02 -5.427521e-04
8.006250e-02 1.212056e-02 1.373510e-02 -1.913416e-03 1.802612e-02
-6.987844e-03 2.236849e-02 6.113689e-03 -1.764951e-02 -7.013665e-03
3.327725e-02 7.304445e-02 7.422731e-03 2.665561e-02 -2.202601e-02
1.115843e-01 5.885387e-03 -3.148265e-03 3.057309e-03 -2.665812e-02
4.052286e-02 -3.243463e-02 3.717924e-02 2.703356e-02 2.929780e-02
```

Vector de 1024 dimensiones que representa a la palabra gato y su significado. 🐱


Embeddings: cuando el significado se vuelve geometría

La **similitud**

coseno es una medida de qué tan parecidos son dos vectores atendiendo solo a su *dirección*, ignorando su magnitud. Formalmente, es el coseno del ángulo entre ellos:



Similitud coseno entre embeddings




1 → los vectores apuntan en la misma dirección (ángulo de 0°): significados muy similares.

0 → vectores ortogonales (90°): sin relación.

-1 → direcciones opuestas (180°).

La ventana de contexto es la memoria de trabajo

La ventana de contexto creció 125 veces en tres años




Actualmente, el estándar es de 1M de *tokens* para los modelos más usados.

Todo lo que entra a la conversación (instrucciones, documentos, historial) consume parte de la ventana de contexto en cada sesión. Cuando se llena, el modelo comienza a olvidar información, aumentan las alucinaciones o el proveedor comienza a cobrar tarifas de contexto largo.

Diseñar el prompt y el proyecto es administrar este presupuesto.

La *temperatura* regula el azar de cada *token*

"La inflación este mes ____": el mismo modelo, dos temperaturas



Regla práctica

Tareas de precisión (extraer datos, clasificar, código): temperatura baja.

Tareas creativas (lluvia de ideas, borradores): temperatura alta.


El ajuste por omisión de los chats queda en medio.

**Aunque realmente esto
cada vez se usa menos.**

Los dos procesos involucrados en un LLM:




Entrenamiento

- * Proceso que ocurre una vez, en centros de datos.
- * Se usan miles de GPUs durante meses; costos de decenas o cientos de millones de USD en energía, enfriamiento y recursos computacionales.
- * Es el proceso mediante el cual el modelo '*aprende*' los patrones del lenguaje a partir de su base (o corpus) de entrenamiento.



Inferencia

- * Proceso que ocurre cada vez que escribimos un *prompt*. Es usar el modelo ya entrenado.
- * Se cobra por *token* procesado y generado.
- * El modelo **ya no aprende**: solo aplica lo aprendido. Por eso existe el corte de conocimiento.



Idea clave

El **entrenamiento** es como estudiar una carrera universitaria: la **inferencia** es como ya ejercer la profesión.

Cuando chateamos con un modelo no lo estamos 'entrenando' en vivo: consumimos inferencia. Esta distinción explica costos, cortes de conocimiento y por qué el modelo no recuerda entre sesiones.



¿Cómo se mide la 'inteligencia' de un modelo?



Benchmark de IA

Un benchmark es un conjunto estandarizado de tareas con respuestas correctas conocidas y un protocolo fijo de calificación, diseñado para medir el desempeño de un modelo en una capacidad específica y compararlo contra otros modelos bajo condiciones idénticas.

Es, en esencia, un examen estandarizado para máquinas: mismas preguntas, mismos criterios de calificación, resultados comparables.

Ejemplo: Artificial Analysis Intelligence Index v4.1

Promedio ponderado de 9 evaluaciones en 4 categorías: agentes (34%), programación (24%), razonamiento científico (24%) y conocimiento general (18%). Líder en agosto de 2026: Claude Opus 5 con 61 puntos.


Los benchmarks tienen letra chica

Contaminación (el modelo pudo ver las preguntas al entrenar), saturación (cuando todos rozan el 100%), Ley de Goodhart (cuando una métrica se convierte en objetivo deja de ser buena métrica), sensibilidad al prompt y al esfuerzo de razonamiento, y un sesgo estructural: casi todo se evalúa en inglés y solo texto.

¿Cuáles son mejores modelos de IA?

Artificial Analysis Intelligence Index: Score


Independently benchmarked by Artificial Analysis



29 of 584 models

+ Add model from specific provider

Artificial Analysis



💡 Reasoning models are indicated by a lightbulb icon

<https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index>

¿A que nos referimos con velocidad?

Tokens por segundo

Ritmo de generación una vez que empieza a responder.

Panel de agosto de 2026: los más rápidos superan los 700-2,000 tokens/s; los punteros de razonamiento van mucho más lento.

Latencia (TTFT)

Segundos hasta el primer token.

En modelos de razonamiento el primer token visible tarda más: primero 'piensan' (y esos tokens también se cobran).

Cuándo importa cada una

Chat en vivo y agentes interactivos: latencia.

Procesamiento masivo de documentos: tokens por segundo y precio por lote.


Índice de tiempo por tarea

Time per Intelligence Index Task

Weighted average decode time (minutes) per task; excludes TTFT and overhead time · Lower is better

29 of 584 models

Artificial Analysis



Reasoning models are indicated by a lightbulb icon

<https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index>


Índice de costo por tareas

Cost per Intelligence Index Task

Weighted average cost (USD) per Artificial Analysis Intelligence Index task, segmented by token type. Lower is better

28 of 584 models

● Answer ● Reasoning ● Cache Write ● Cache Hit ● Input




💡 Reasoning models are indicated by a lightbulb icon

① Cost per Intelligence Index Task


<https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index>

Elegir modelo es pararse dentro de un triángulo



No hay modelo 'mejor' en abstracto: hay un mejor punto del triángulo para cada tarea y presupuesto.


La misma inteligencia cuesta 10 veces menos cada año



El ~10x anual de a16z es el piso: Epoch AI estima de 9x a 900x según el umbral (mediana ~50x).
Lo que hoy es caro de automatizar, en un año probablemente no lo será.

No todos los idiomas cuestan lo mismo

El mismo texto cuesta 1.31x en español y hasta 13x en malayalam
(tokenizador cl100k_base, corpus FLORES-200)




El español paga entre un 10% y un 30% de sobreprecio

A esto se le llama fertilidad del tokenizador: cuántos tokens produce por palabra. Mayor fertilidad = misma idea, más tokens, más dinero.

Con fertilidad 1.25x, una ventana de 128k tokens equivale a ~102k tokens de contenido en inglés: caben menos documentos nuestros.

La raíz del problema: la web que entrena a los modelos


En la principal fuente de entrenamiento hay 8.7 veces más inglés que español



Menos datos de entrenamiento en español se asocia con brechas de desempeño documentadas (MEGA, Global-MMLU), aunque el español, por ser lengua de altos recursos, sufre mucho menos que otras.


Historia de los LLMs desde ChatGPT

Cuatro años que cambiaron a la industria



Fuente: Wikipedia y anuncios oficiales de cada laboratorio. Corte: agosto de 2026.

ChatGPT rompió récords de adopción




Fuente: Wikipedia, ChatGPT (consultado el 1 de agosto de 2026).

30 de noviembre de 2022

GPT-3.5 + RLHF (ajuste con retroalimentación humana).

Gratuito y conversacional: la IA dejó de ser tema de laboratorio y se volvió un producto de consumo masivo.

Growth in fraction of Internet users since launch



2023-2024: surgen nuevos modelos

★ Modelo multimodal

Es un modelo de IA que puede trabajar con varios tipos de información a la vez (como texto, imágenes, audio y video) y entenderlos en conjunto.



GPT-4 (mar 2023)

GPT-4o

Multimodal, aprueba exámenes profesionales; GPT-4o (2024) responde en tiempo real con voz e imagen.

Claude (mar 2023)

Apuesta por contextos largos: 100k *tokens* en 2023, 200k en 2024. Introduce *Artifacts* (piezas de contenido separadas de la conversación principal).



Gemini (dic 2023)

Gemini 1.5, modelo de IA que lleva la ventana de contexto a 1 millón de tokens (2024).

Llama (2023-2024)

Meta libera **pesos abiertos**: cualquiera puede descargar y ejecutar el modelo en equipo propio. **Nace el ecosistema abierto.**

LLaMA 2




2024: los modelos aprenden a 'pensar' antes de responder

Modelos de razonamiento (o1, septiembre de 2024)

El modelo genera una **cadena de razonamiento** (o de **pensamiento**) **interna** antes de contestar.

Esto permite resolver problemas de varios pasos **generando pasos intermedios** antes de dar la respuesta final: **descompone el problema, explora caminos, verifica resultados parciales, se corrige, y luego responde.**

Más lento y más caro, pero con mejores resultados en temas como matemáticas, ciencia y código.



El salto medible

En el examen de matemáticas AIME (*American Invitational Mathematics Examination*): o1-preview logró 83% frente a 13% de GPT-4o (Septiembre 2024).

Fuente: Wikipedia, OpenAI o1 (consultado el 1 de agosto de 2026).

razonamiento: para completar "la capital de Morelos es..." no basta la gramática, ha

ue Higher effort means more thorough responses, but takes longer and uses your limits faster.

Low
Medium
High ☒ Default
Extra
Max

rite a message...

l mínima de texto que el modelo
agmento ("ción", "pre-"), un caracte
proceso de convertir texto crudo en 1

Table 5
For your toughest challenges
Effort High
More models

Table 5 High

¿Por qué importa?

Hoy casi todos los modelos punteros ofrecen 'esfuerzo de razonamiento' ajustable: más pensamiento cuesta más tokens.

Ejemplo con Qwen3.5:4b



Qwen3.5



Hola, oye, cuanto es 2 + 2?

Thought for 7.3 seconds

Thinking Process:

1. Analyze the Request:

- Language: Spanish ("Hola, oye, cuánto es 2 + 2?", Hello hey what is 2+2).
- Task: Calculate and provide a simple arithmetic result (2 plus 2 equals 4).

2. Determine the Answer:

- $2 + 2 = 4$.

3. Formulate the Output:

- Keep it friendly and direct, matching the casual tone of the user ("Hola, oye").
- Language: Spanish (to match the query).

4. Draft Response (Internal Monologue):

- Option 1 (Too formal): El resultado de $2 + 2$ es 4.
- Option 2 (Casual & Friendly): ¡Hola! Es 4, mucho más fácil así mismo. No no... just tell them the answer.
- Draft: Hola, oye, el resultado son cuatro. O sea 4.

5. Final Polish: Keep it simple and accurate. "¡Es 4!" or "La respuesta es 4". Let's go with a friendly response acknowledging the greeting.

6. Output Generation (Spanish): Hola! El resultado de $2 + 2$ es 4.cw

¡Hola! ¡El resultado de $2 + 2$ son cuatro (4)!



Enero de 2025: DeepSeek sacude los mercados



~\$5.6 millones USD


costo de entrenamiento reportado de DeepSeek-V3, frente a ~\$100 millones de USD reportados para GPT-4.

Licencia MIT

La primera versión liberó código y pesos abiertos: razonamiento de frontera para cualquiera.

-18% Nvidia en un día

~\$600 mil millones USD de capitalización perdidos: la mayor caída de una empresa en la historia bursátil de EUA hasta la fecha.



Lección: la eficiencia **también es una frontera de investigación**, no solo el tamaño o la inteligencia.



Modelo de IA de pesos abiertos




Un modelo de pesos abiertos es aquel cuyos parámetros entrenados — el archivo con los miles de millones de números que codifican todo lo aprendido — se publican para que cualquiera pueda descargarlos, ejecutar el modelo en su propia infraestructura, inspeccionarlo o hacerle ajuste fino (*fine-tuning*). Ejemplos: Llama (Meta), Qwen (Alibaba), DeepSeek, Mistral, Gemma (Google).

Modelos de pesos abiertos

Artificial Analysis Intelligence Index: Score


Independently benchmarked by Artificial Analysis



29 of 584 models

+ Add model from specific provider

Artificial Analysis



💡 Reasoning models are indicated by a lightbulb icon

<https://artificialanalysis.ai/evaluations/artificial-analysis-intelligence-index>

Modelos de pesos abiertos

- * Los LLMs en última instancia **son archivos** que guardan los miles de millones de pesos de los modelos entrenados por las empresas de IA, y como tal, también se pueden descargar.
- * Esos archivos se **ejecutan en programas como Ollama o LM Studio** (de descarga libre).
- * Aunque se puedan descargar, muchos de los LLMs son programas tan pesados que requieren equipos muy potentes para poder funcionar (mucho memoria RAM, mucha vRAM, uso de GPUs).
- * Una regla de dedo para saber cuanta vRAM utilizaría un modelo: por cada 1B (one billion, mil millones) de parámetros (pesos), se ocupa 1GB de RAM.



ollama list

NAME	ID	SIZE	MODIFIED
nomic-embed-text:latest	0a109f422b47	274 MB	14 hours ago
gemma4:12b	4eb23ef187e2	7.6 GB	2 months ago
gemma3:1b	8648f39daa8f	815 MB	3 months ago
gemma4:e4b	c6eb396dbd59	9.6 GB	4 months ago
qwen3.5:9b	6488c96fa5fa	6.6 GB	5 months ago
qwen3.5:4b	2a654d98e6fb	3.4 GB	5 months ago
bge-m3:latest	790764642607	1.2 GB	9 months ago

¿Quién controla el modelo? Dos mundos



 Gemini

Modelos Propietarios (API, suscripción)

GPT, Claude, Gemini.

Máxima capacidad, cero infraestructura propia.

Los datos viajan al proveedor; el modelo puede cambiar o desaparecer sin aviso.



Qwen3.5



Modelos de Pesos abiertos

Llama, DeepSeek, Qwen, Gemma.

Se descargan y corren donde quieras: privacidad y control de versiones.

Requieren hardware propio y trabajo de ingeniería.

'Abierto' tiene grados: pesos abiertos no siempre implica datos de entrenamiento abiertos ni licencia sin restricciones. DeepSeek-R1 (licencia MIT) es de los más permisivos.

¿Puedo correr un LLM en mi laptop?



Respuesta corta: sí

No **necesitas** esto de la izquierda.

Un modelo de 8 mil millones de parámetros cuantizado pesa ~5 GB y corre en una laptop con 16 GB de RAM, sin GPU.

La pregunta interesante es **cuál** modelo y a **qué** velocidad.

Conceptos de Hardware

★ GPU (Graphics Processing Unit)

Es la unidad de procesamiento gráfico, también conocida como tarjeta gráfica. Originalmente se diseñó para renderizar imágenes y video (de ahí el nombre), pero su arquitectura resultó ser perfecta para otra cosa: hacer miles de operaciones matemáticas sencillas *en paralelo*, lo que la hace ideal para cargar los pesos o parámetros de las redes neuronales de la IA.



<https://www.youtube.com/watch?v=h9Z4oGN89MU>


★ VRAM (Video RAM)

Es la memoria dedicada que vive físicamente en la tarjeta gráfica, soldada junto al chip de la GPU. Cumple la misma función que la RAM — guardar temporalmente los datos que se están procesando — pero es exclusiva de la GPU y está diseñada para lo que ella necesita: mover cantidades enormes de datos a velocidades muy altas.

La diferencia clave con la RAM normal es el **ancho de banda**. La VRAM (tecnologías como GDDR6 o GDDR7) puede transferir datos mucho más rápido que la RAM del sistema

En 2026: la memoria es el recurso caro

Los centros de datos de IA absorben ~70% de la memoria mundial:
la GPU de consumo cuesta más del doble de su precio de lista



Apple retiró sus configuraciones de 256 y 512 GB y subió precios en junio de 2026; las GPU de consumo se venden al doble de su precio de lista. Planeen hardware con esta realidad.

Recursos para profundizar

Documentos del curso (Canvas): 'Precio, inteligencia y velocidad' y 'El idioma en el costo y rendimiento', con fuentes verificadas.

Tablero comparativo de modelos: artificialanalysis.ai/models

Contador de tokens: platform.openai.com/tokenizer y el endpoint `count_tokens` de Anthropic.

Appenzeller, G. (a16z): 'Welcome to LLMflation'.

Srivastava (2026): 'The Tokenizer Tax', arXiv:2607.24276.

Gracias

¿Preguntas?