

10. RAG

Ciencia de datos II

**Jorge Juvenal
Campos Ferreira**

✉ juvenal.campos@tec.mx

La sesión recorre el flujo completo, de las mañaneras crudas a una respuesta con cita

1. El problema

Qué sabe y qué no sabe un modelo de lenguaje, y por qué inventa cuando no sabe.

2. El corpus

71 mañaneras convertidas en texto plano con fecha y fuente, descargadas con R.

3. El flujo de trabajo

Fragmentar, convertir en vectores, guardar, buscar y redactar. Dos demostraciones en vivo.

4. La evaluación

Cómo sabemos si funcionó, qué mide hit@5 y qué no mide, y dónde falla el sistema.

Un modelo de lenguaje predice la siguiente palabra, y con eso redacta, resume y conversa

predice la siguiente palabra

Eso es todo lo que hace. Y con eso basta para responder preguntas, resumir y redactar con fluidez.

Modelo de lenguaje grande

Un modelo estadístico entrenado con enormes cantidades de texto para predecir qué palabra sigue. Todo lo que "sabe" quedó fijado en sus parámetros durante el entrenamiento: al responder no consulta nada.


Token

La unidad mínima con la que trabaja: un fragmento de palabra. En español, mil tokens son unas 600 o 700 palabras. Costos, límites y tamaños de fragmento se miden en tokens.

Ventana de contexto

Cuántos tokens puede leer de una sola vez. En el modelo de la sesión son 8,192 tokens, unas 5,000 palabras. Una mañana completa tiene unas 14,000: no cabe.

Lo que el modelo sabe se congeló en su fecha de corte: no leyó la mañana de ayer



Fecha de corte del conocimiento

Es la fecha hasta la que llegan los datos con los que se entrenó el modelo. Todo lo posterior no existe para él. Tampoco conoce nunca lo que no estaba en internet al entrenarse: actas internas, bases propias, encuestas sin publicar. Las mañaneras son el caso extremo: hay una nueva cada día hábil y cada una trae cifras, nombres y anuncios que no estaban en ningún lado la víspera.

Cuando no sabe, el modelo no se calla: afirma con seguridad cosas falsas

¿Cuál fue el promedio diario de homicidios dolosos en México en agosto de 2026, según lo que informó la presidenta Claudia Sheinbaum en su conferencia de prensa?

Sin documentos: qwen3.5:4b, respuesta textual

“Es imposible proporcionar ese dato específico porque se trata de un futuro hipotético; Claudia Sheinbaum no ha sido electa ni habrá emitido tal información, dado que el mes de agosto de 2026 aún no ha ocurrido. Por lo tanto, cualquier cifra sobre el promedio diario de homicidios dolosos en esa fecha específica sería una suposición imaginaria y no reflejaría la realidad futura ni los informes oficiales existentes.”

Lo que dijo la mañanera del 8 de septiembre

“...el mes que acaba de concluir que cerró en un promedio de 40.8 homicidios diarios, siendo además este agosto de 2026 el mes más bajo de estos meses analizados.”

El modelo no solo desconoce el dato: asegura que agosto de 2026 no ha ocurrido y que Sheinbaum no ha sido electa. Todo dicho con el mismo tono seguro.

Alucinación

Una afirmación fluida, con el tono correcto, y falsa. Ocurre porque el modelo optimiza plausibilidad, no verdad. Sin la fuente a la mano no hay forma de distinguirla de una respuesta correcta.

De las tres formas de darle información nueva a un modelo, solo una escala a un corpus que cambia cada día


	Ajuste fino	Contexto largo	RAG
Qué hace	Reentrena parte del modelo con datos propios	Pega todos los documentos en el prompt	Busca los fragmentos relevantes y solo pega esos
Costo	Alto: horas de cómputo por versión	Bajo por consulta, pero crece con el corpus	Bajo: el índice se construye una vez
Actualización	Reentrenar	Volver a pegar todo	Agregar archivos al almacén
Cita la fuente	No	Difícil	Sí: es su ventaja central
Límite	Datos que cambian cada mes	Miles de documentos no caben	Depende de que la búsqueda acierte

Con 71 maneras el contexto largo ya no alcanza

Son 6 millones de caracteres, alrededor de 1.5 millones de tokens. Ni siquiera caben completas en los modelos comerciales, y aunque cupieran, el modelo se distrae con el ruido.

RAG resuelve el problema con una regla simple: buscar primero, redactar después

Con RAG



Sin RAG



RAG: generación aumentada por recuperación

Antes de responder, el sistema busca en una colección de documentos los fragmentos relevantes y se los entrega al modelo como contexto. El modelo responde a partir de ese material, no de su memoria. El término lo acuñaron Lewis et al. (2020).

Dos modelos, dos trabajos


Uno busca (el modelo de embeddings) y otro redacta (el generador). Se cambian por separado: el corpus y el índice no se tocan al cambiar de generador. Y como el material viene con fecha, la respuesta puede citar de dónde salió cada dato.

¿Cuándo usar RAG?

Casos típicos:

- **Conocimiento que el modelo no tiene:** documentos internos, datos posteriores a su entrenamiento, información que cambia seguido (precios, reglamentos, noticias).
- **Corpus demasiado grande para el contexto:** si tienes 5 mil PDFs, no caben en una ventana de 200k tokens; RAG saca solo los fragmentos pertinentes.
- **Trazabilidad:** cuando necesitas que la respuesta cite la fuente exacta (un artículo, una cláusula, una página).
- **Reducir alucinaciones en dominios cerrados:** soporte al cliente, consulta de normativas, bases de conocimiento donde inventar es inaceptable.

Fase de Indexación




Morado: transformación de texto · Verde: representación numérica y búsqueda

Fase de Consulta



Verde: búsqueda en el espacio vectorial · Morado: generación con el modelo de lenguaje

El corpus son 71 mañaneras en texto plano, con fecha y fuente, descargadas con R



Corpus

El conjunto de documentos sobre los que el sistema responde: las versiones estenográficas del 1 de junio al 8 de septiembre de 2026, publicadas en gob.mx.


Ingesta

Se descargó con un navegador controlado desde R (chromote), porque el sitio bloquea las descargas automáticas comunes, y el texto se extrajo con rvest.

Metadatos

Cada archivo conserva título, fecha y URL, y un párrafo por turno de palabra con el orador en mayúsculas. Son lo que permite filtrar y citar.

Una mañanera no cabe en el modelo ni conviene que quepa: se parte en fragmentos



Por qué fragmentar

El modelo de embeddings tiene un límite de entrada. Un vector resume todo el texto que recibe: si habla de diez temas, no se parece a ninguna pregunta. Y el generador solo puede leer unos pocos fragmentos a la vez.


Tamaño y traslape

Tamaño objetivo de 1,600 caracteres (unos 400 tokens) en el programa. Traslape de 25 %: cada fragmento repite el último cuarto del anterior para que ninguna idea quede partida en la frontera.

Dónde cortar

ragnar mueve cada corte al límite de párrafo más cercano. Como cada párrafo es un turno de palabra, los fragmentos rara vez separan al orador de lo que dijo.

Con 1,600 caracteres y 25 % de traslape, 26 mañaneras se convierten en 1,824 fragmentos



Es el primer parámetro que se ajusta en cualquier proyecto de RAG. No hay un valor correcto universal: depende de cómo están escritos los documentos.

Chicos (800): 3,644 fragmentos

Vectores más precisos, pero una cifra puede quedar separada de la oración que la explica. El doble de fragmentos que embeber.

Medianos (1,600): 1,824

El punto de partida del script: unos 70 por mañanera. Cabe un turno de palabra completo.

Grandes (3,200): 915

Conservan el argumento entero, pero diluyen el significado y llenan la ventana del generador con dos o tres.

Un modelo de embeddings convierte cada fragmento en 1,024 números que guardan su significado, no sus palabras

Fragmento 1 · 574 caracteres

"Les adelanto que, entre septiembre de 2024 y jun..."

bge-m3 lo convierte en:

-0.0214	+0.0069	-0.0090	-0.0381	-0.0635
-0.0386	+0.0058	+0.0177	-0.0280	+0.0444

... 1,004 números más ...

-0.0033	-0.0211	+0.0128	+0.0253	+0.0103
-0.0268	+0.0257	-0.0106	-0.0039	-0.0171

Fragmento 2 · 516 caracteres

"Esa es la cifra que queremos compartir el día de..."

bge-m3 lo convierte en:

+0.0018	-0.0221	-0.0308	-0.0187	-0.0389
-0.0406	-0.0104	+0.0173	-0.0325	+0.0326

... 1,004 números más ...

+0.0180	-0.0160	+0.0013	+0.0136	+0.0025
-0.0167	-0.0133	+0.0360	+0.0071	+0.0062

Embedding y modelo de embeddings

Un embedding es la representación de un texto como un vector de números: textos con significado parecido quedan en puntos cercanos, aunque usen palabras distintas. El modelo que lo produce (bge-m3, multilingüe, 1,024 dimensiones) es distinto del que redacta: es pequeño, rápido y no genera texto. Tarda 0.1 segundos por fragmento en una computadora portátil.

La regla que no se puede romper


Ningún número del vector significa algo por sí solo: importa la posición del vector completo respecto a los demás. Por eso el modelo que embebe el corpus debe ser el mismo que embebe las preguntas. Vectores de dos modelos distintos viven en espacios distintos y no se pueden comparar.

La pregunta se convierte al mismo espacio y se mide qué fragmento le queda más cerca

Similitud y distancia coseno

La similitud coseno es el coseno del ángulo entre dos vectores: 1 si apuntan en la misma dirección, 0 si no tienen relación. La distancia es 1 menos la similitud. Buscar "por significado" es calcular esa distancia entre la pregunta y cada fragmento y quedarse con los menores.

Pregunta	Fragmento 1 (trae el 48 %)	Fragmento 2 (la coda)
¿Cuánto bajó el homicidio doloso?	0.310	0.431
¿Cuál es la meta de viviendas en Tlaxcala?	0.646	0.605



Los fragmentos, sus metadatos y sus vectores viven en un solo archivo DuckDB con un índice para buscar rápido

origin	chunk_id	start	end	fecha	titulo	url	embedding	text
2026-09-08_...txt	1	1	1601	2026-09-08	Versión estenográfica...	gob.mx/...	[-0.021, 0.007, ... ×1024]	PRESIDENTA DE MÉXICO...
2026-09-08_...txt	2	1202	2803	2026-09-08	Versión estenográfica...	gob.mx/...	[0.002, -0.022, ... ×1024]	Hoy es el informe de...
...	...	...	...	...	...	...	...	...
2026-08-03_...txt	1824	...	...	2026-08-03	Versión estenográfica...	gob.mx/...	[...]	...

Amarillo: metadatos que se filtran y se citan · Azul: el vector con el que se busca

Base de datos vectorial

Guarda fragmentos junto con sus embeddings y responde consultas de "vecinos más cercanos". Aquí es DuckDB, una base analítica embebida en un archivo de 37 MB.

Qué tiene cada fila

Texto del fragmento, documento de origen, posiciones inicial y final, fecha, título, URL y el vector de 1,024 números.

Índice

Acelera la búsqueda: en vez de comparar la pregunta con los 1,824 vectores uno por uno, aproxima el resultado en una fracción del tiempo. Se reconstruye al agregar documentos. Construirlo tardó 2.6 minutos, una sola vez.

La búsqueda semántica encuentra sinónimos, la léxica encuentra nombres y cifras, y la híbrida se queda con lo mejor de ambas

Pregunta: ¿Cuál fue el promedio diario de homicidios dolosos en agosto de 2026?

Semántica (distancia coseno)

- 09-08 0.28**
El día de hoy —como ya decía la Presid...
- 08-11 0.31**
En esta primera gráfica vemos la tende...
- 08-11 0.32**
En la siguiente gráfica ahora presenta...
- 09-04 0.35**
Como puede apreciarse claramente, hay ...
- 09-04 0.38**
Por eso es virtuoso y por eso en Zacat...

Léxica BM25 (puntaje)

- 09-08 12.90**
El día de hoy —como ya decía la Presid...
- 09-04 11.82**
Como puede apreciarse claramente, hay ...
- 08-11 11.59**
En la siguiente gráfica ahora presenta...
- 08-11 11.56**
En esta primera gráfica vemos la tende...
- 09-04 11.48**
Por eso es virtuoso y por eso en Zacat...

Híbrida: 5 recuperados, 3 tras fusionar vecinos

- 08-11 cos 0.31 · bm25 11.6**
En esta primera gráfica vemos la tende...
- 09-04 cos 0.35 · bm25 11.5**
Por eso es virtuoso y por eso en Zacat...
- 09-08 cos 0.28 · bm25 12.9**
El día de hoy —como ya decía la Presid...

Semántica (VSS)

Compara embeddings. Encuentra "reducción de homicidios" cuando se pregunta por "baja en la violencia".

Léxica (BM25)

Compara palabras, ponderadas por qué tan raras son en el corpus. Gana con términos exactos: "Kanasín", "Hemosa Ingeniería", "40.8". En mañaneras pesa mucho.

Híbrida, con top-k = 5

Ejecuta las dos y fusiona las listas; es la opción por defecto de ragnar. top-k es cuántos fragmentos se recuperan (5 aquí). Cuando dos vecinos del mismo documento se traslapan, ragnar los une: por eso la lista híbrida muestra 3.

La fecha permite acotar la búsqueda antes de buscar: qué dijo sobre aranceles la primera semana de septiembre

Consulta: "aranceles a países sin tratado de libre comercio"

Sin filtro: fechas de todo el corpus

2026-08-04

Entonces, la orientación de la Consejería Jurídica es pone...

2026-08-13

Entonces, aumenta la eficiencia del paso de las mercancías...

2026-08-14

COMISIONADO DEL INSTITUTO NACIONAL DE MIGRACIÓN (INM), SER...

2026-08-24

PREGUNTA: Presidenta, en otra pregunta ya para terminar, q...

2026-09-02

Y, bueno, miren, nada más Aduanas, desde que llegamos el a...

Con filtro del 1 al 7 de septiembre

2026-09-02

Y hay dos preguntas que me gustaría hacerle sobre su infor...

2026-09-02

Preguntarle, porque ahí en el informe no se detalla si est...

2026-09-03

Y, por último, Presidenta, ayer se reunió el secretario de...

2026-09-04

SECRETARIO DE LA DEFENSA NACIONAL, RICARDO TREVILLA TREJO:...

2026-09-04

PRESIDENTA DE MÉXICO, CLAUDIA SHEINBAUM PARDO: Sí, se ha i...

2026-09-07

Entonces, ya el solo hecho del crecimiento de la Pensión A...

Filtro por metadatos

Los metadatos guardados con cada fragmento se usan como filtro previo: primero se descartan los fragmentos fuera del periodo y luego se ordena por cercanía. Sin filtro, la misma consulta trae fechas de todo el corpus.

Lo nuevo frente a un corpus de PDFs sueltos

En un corpus fechado, buena parte de las preguntas reales traen un periodo: "en julio", "después del informe", "esta semana". Acotar antes de buscar funciona mejor que dejar que la similitud adivine el periodo.

"Aumentar" el prompt significa literalmente pegarle los cinco fragmentos antes de la pregunta

Instrucción de sistema

Eres un asistente que responde preguntas sobre las conferencias de prensa matutinas de la presidenta de México. Responde SOLO con la información de los fragmentos que se te entregan y menciona la fecha de la mañanera de donde sale cada dato. Si la información no está en los fragmentos, di explícitamente que no aparece en las mañaneras consultadas. Responde en español, en máximo cinco oraciones.

Fragmentos recuperados (7,354 caracteres en total)

[Mañanera del 11/08/2026]

En esta primera gráfica vemos la tendencia en el promedio diario de homicidio doloso de fo...

[Mañanera del 04/09/2026]

Por eso es virtuoso y por eso en Zacatecas hemos privilegiado el tema de seguridad, porque...

[Mañanera del 08/09/2026]

El día de hoy —como ya decía la Presidenta— les presentaremos el Reporte de Incidencia Del...

Pregunta

¿Cuál fue el promedio diario de homicidios dolosos en agosto de 2026?

Prompt aumentado

Es el mensaje final que recibe el generador: instrucciones, fragmentos recuperados (cada uno con su fecha) y la pregunta. En el ejemplo mide 7,354 caracteres, unos 1,800 tokens: cabe de sobra en la ventana de 8,192.

Instrucción de sistema

El texto fijo que establece las reglas: responder solo con el contexto, citar la fecha y decir "no aparece" cuando no esté. Es la primera defensa contra la alucinación, pero no es una garantía: un modelo pequeño la desobedece a veces.

El generador redacta a partir de los fragmentos y cita la mañanera de donde salió cada dato

Respuesta real de qwen3.5:4b, 13 segundos

“El promedio diario de homicidios dolosos en México cerró en 40.8 en agosto de 2026, cifra confirmada por la Presidenta Claudia Sheinbaum en su conferencia de prensa del día 8 de septiembre de 2026. Esta representación gráfica muestra que el mes representa el promedio más bajo registrado en los últimos 12 años analizados hasta la actualidad. Para el estado de Zacatecas, el informe presentado el 4 de septiembre de 2026 indica un dato preliminar de 0.17 homicidios diarios por día para agosto del mismo año. Ambos registros demuestran una reducción significativa respecto a septiembre de 2024 y constituyen los mínimos históricos reportados en los periodos analizados.”

Modelo generador

El LLM que escribe la respuesta. Aquí corre en la computadora; puede cambiarse por Claude o GPT sin tocar el almacén.

Atribución


Cada afirmación se puede rastrear a un fragmento con fecha y verificar. Es la ventaja central de RAG sobre un modelo sin fuentes.

Qué verificar en la respuesta

Las dos fechas citadas (8 y 4 de septiembre) corresponden a fragmentos que sí estaban en el prompt, y las cifras (40.8 y 0.17) aparecen textualmente en ellos. Lo que sí agregó el modelo por su cuenta es la frase "en los últimos 12 años", que no está en los fragmentos: incluso con la fuente enfrente conviene leer con lápiz.

En la variante con herramienta, el modelo decide cuándo buscar y con qué palabras

Variante con herramienta: la búsqueda deja de ser un paso fijo y se vuelve una función que el modelo invoca



Herramienta y llamada a herramientas

Una herramienta es una función que el modelo puede invocar. La búsqueda se registra como herramienta y el modelo la llama con la consulta que él mismo formula, a veces varias veces. Sirve para preguntas compuestas y conversaciones largas. Con modelos pequeños la herramienta devuelve texto plano y solo tres fragmentos, porque las salidas largas los confunden.

Respuesta real por herramienta

"Según los datos de la mañanera del 13/08/2026, los pasajeros internacionales transportados por el Tren Maya fueron 56 mil 763 en ese periodo específico. La misma cifra es confirmada en la información de la mañanera del 08/09/2026, que especifica que este volumen representa un aumento del 37.7 por ciento respecto al mismo periodo anterior. Ambos documentos señalan que este crecimiento ha contribuido significativamente al impulso turístico y económico en el sur de México."

Ante una pregunta sin respuesta en el corpus el sistema debe abstenerse, y el modelo pequeño lo logró al segundo intento

¿Qué dijo la presidenta sobre el resultado del Mundial de 2030? (no hay nada en las mañaneras)

Intento 1: el modelo divaga

“En la mañanera del 12/08/2026, la presidenta no mencionó resultados específicos sobre un Mundial de 2030. Señaló que México regresó del último torneo realizado con el primer lugar del medallero general y 407 medallas, lo cual consolidó al país como líder de su región. A pesar de no haber datos concretos sobre el Mundial de 2030 en la información consultada, se enfatizó el espíritu de ser grandes anfitriones si algún evento similar tuviera lugar en México.”

Intento 2: el modelo se abstiene

“No aparecen datos específicos del Mundial de 2030 en las mañaneras consultadas. Se mencionó que México consolidó un récord deportivo tras el último torneo disputado en la región, pero no hay referencias sobre los resultados o expectativas para dicho evento futuro.”

Lección

La recuperación fue correcta las dos veces: no había nada relevante que traer. La generación es la que falla. Un sistema de RAG hereda los errores de sus dos modelos, y con un generador más grande el primer intento no habría ocurrido. Aun así, la instrucción de sistema no garantiza nada: hay que evaluar.

Con ocho preguntas de respuesta conocida, los tres métodos recuperaron la mañanera correcta el 100 % de las veces

Pregunta	Mañanera esperada	Semántica	Léxica	Híbrida
¿Cuántos pasajeros internacionales ha transportado el Tren Maya?	2026-08-13	Sí	Sí	Sí
¿Cuántas tarjetas para remesas otorgó Financiera para el Bienestar?	2026-08-14	Sí	Sí	Sí
¿Cuál es la meta de viviendas en Tlaxcala?	2026-08-19	Sí	Sí	Sí
¿Cuántas viviendas se construirán en Kanasín?	2026-08-12	Sí	Sí	Sí
¿A qué empresas se adjudicó el mantenimiento de las vías del Tren Maya...	2026-09-03	Sí	Sí	Sí
¿Cuántas personas resultaron lesionadas en la agresión en Zacatecas?	2026-09-04	Sí	Sí	Sí
¿Cuál fue el promedio diario de homicidios dolosos en agosto de 2026?	2026-09-08	Sí	Sí	Sí
¿Cuándo se pusieron aranceles a países sin Tratado de Libre Comercio?	2026-09-02	Sí	Sí	Sí
hit@5		100 %	100 %	100 %

Conjunto de prueba

Preguntas con respuesta y fragmento esperado, escritas a mano por quien conoce el corpus. Sin él no se sabe si un cambio mejoró o empeoró el sistema.

hit@k

Proporción de preguntas para las que el documento correcto aparece entre los k primeros recuperados. La métrica más simple y la primera que se calcula.

Lo que hit@5 no mide

Fidelidad: si la respuesta se sostiene solo en los fragmentos. Completitud: si cubre todo lo preguntado. La diapositiva anterior es un fallo de fidelidad con recuperación perfecta.

Cada parámetro del flujo es una decisión con costo: tamaño de fragmento, top-k, modelo y equipo

Tamaño de fragmento y traslape

Afectan precisión y volumen. Se ajustan con el conjunto de prueba, no por intuición.

top-k

Más fragmentos, más cobertura y más ruido.
También más tokens y más tiempo de respuesta.

Modelos y equipo

Embeddings locales (bge-m3, 0.1 s por fragmento) y generador local (qwen3.5:4b, 12 s por respuesta) corren en una computadora portátil de 16 GB. Un generador remoto responde en 2 s, pero requiere llave y envía el texto fuera.

Corpus

RAG no arregla un corpus malo: si la transcripción tiene errores o le faltan días, las respuestas los heredan.

Los términos de la sesión, en el orden en que aparecen en el flujo de trabajo

El problema y el corpus

Modelo de lenguaje grande

Token

Ventana de contexto

Fecha de corte del conocimiento

Alucinación

RAG (generación aumentada por recuperación)

Corpus

Ingesta

Metadatos

Fragmentación, tamaño y traslape

Búsqueda, generación y evaluación

Embedding y modelo de embeddings

Similitud coseno

Base de datos vectorial e índice

Búsqueda semántica, léxica e híbrida

top-k y filtro por metadatos

Prompt aumentado e instrucción de sistema

Herramienta

Modelo generador y atribución

Conjunto de prueba y hit@k

Fidelidad y completitud

Todo el material corre en R con tres herramientas de código abierto y sin llaves de API

Ollama

Ejecuta modelos de lenguaje y de embeddings en la computadora local, sin enviar datos a ningún servidor.

```
ollama pull bge-m3  
ollama pull qwen3.5:4b
```

ragnar

Paquete de R de Posit con el flujo completo de RAG: lectura, fragmentación, embeddings, almacén DuckDB y búsqueda híbrida (Kalinowski y Falbel, 2026).

ellmer

Paquete de R de Posit para conversar con modelos de cualquier proveedor y registrar herramientas.

Programas de la sesión

01_scraper_mananeras.R: descarga el corpus desde gob.mx.

02_rag_mananeras.R: el flujo completo, con las dos demostraciones.

glosario_rag.md: definiciones y referencias.

Lecturas

Lewis et al. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS 33.

Robertson y Zaragoza (2009). The probabilistic relevance framework: BM25 and beyond.

Kalinowski y Falbel (2026). ragnar 0.3.0, CRAN.

Cinco ideas para llevarse

- 1 Un modelo de lenguaje redacta bien pero no consulta nada: lo que no estaba en su entrenamiento lo inventa.
- 2 RAG cambia la regla: buscar primero, redactar después, y citar de dónde salió cada dato.
- 3 Intervienen dos modelos distintos: el de embeddings busca por significado; el generador redacta. Se cambian por separado.
- 4 La calidad depende de decisiones concretas: cómo se fragmenta, cuántos fragmentos se recuperan y qué tan bueno es el corpus.
- 5 Nada de esto se sabe sin evaluar: un conjunto de prueba escrito a mano vale más que cualquier intuición.

Gracias

¿Preguntas?