Tecnológico de Monterrey

12. Pre procesamiento de texto en R

Ciencia de datos para la toma de decisiones II

Jorge

Juvenal

Campos Ferreira

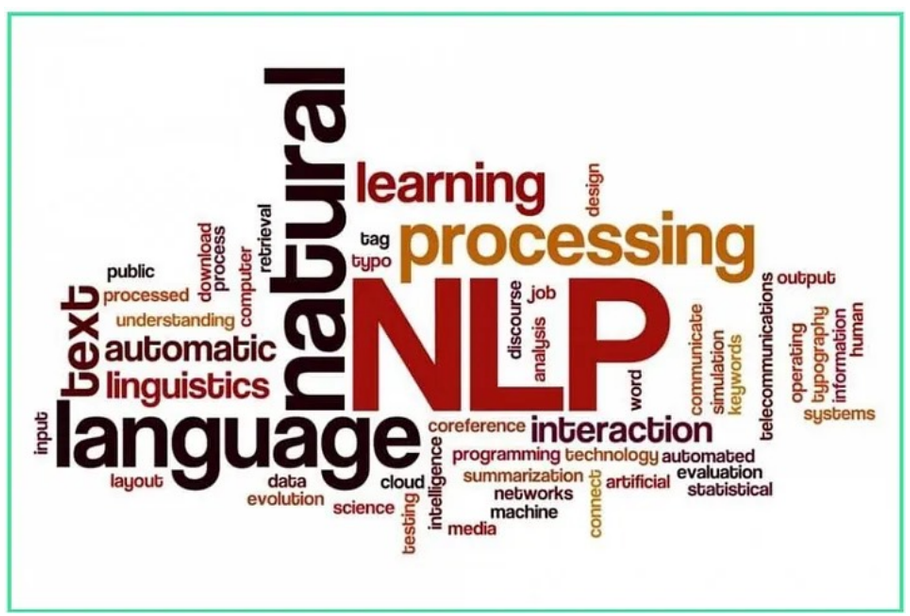
juvenal.campos@tec.mx

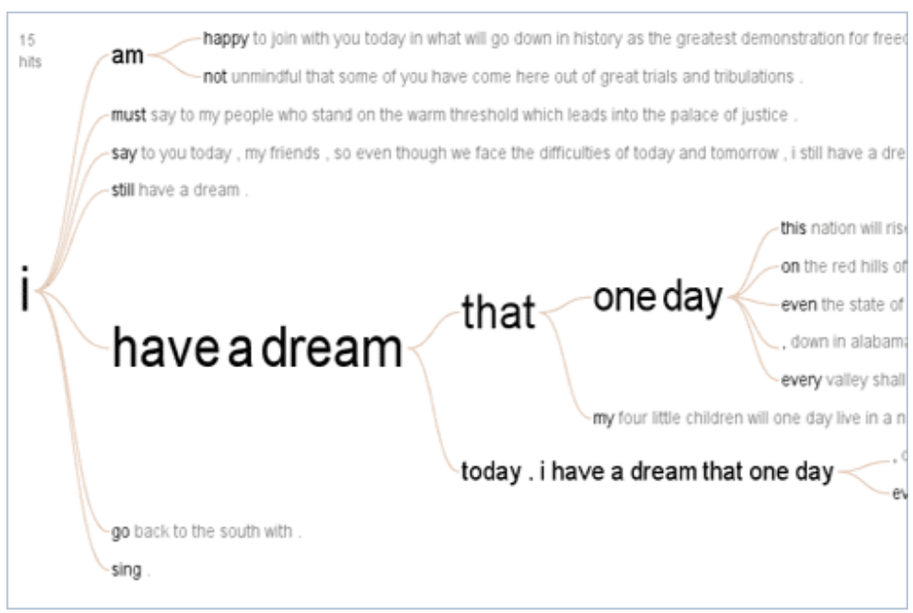
Texto como datos

Es un enfoque para tratar al lenguaje (documentos, posts, discursos, leyes, noticias, reseñas) como datos cuantificables, de modo que se pueda analizar con métodos estadísticos o de *Machine Learning*.

La diferencia con los datos numéricos es:

1) Alta dimensionalidad.
2) Requiere métodos especializados para su análisis.

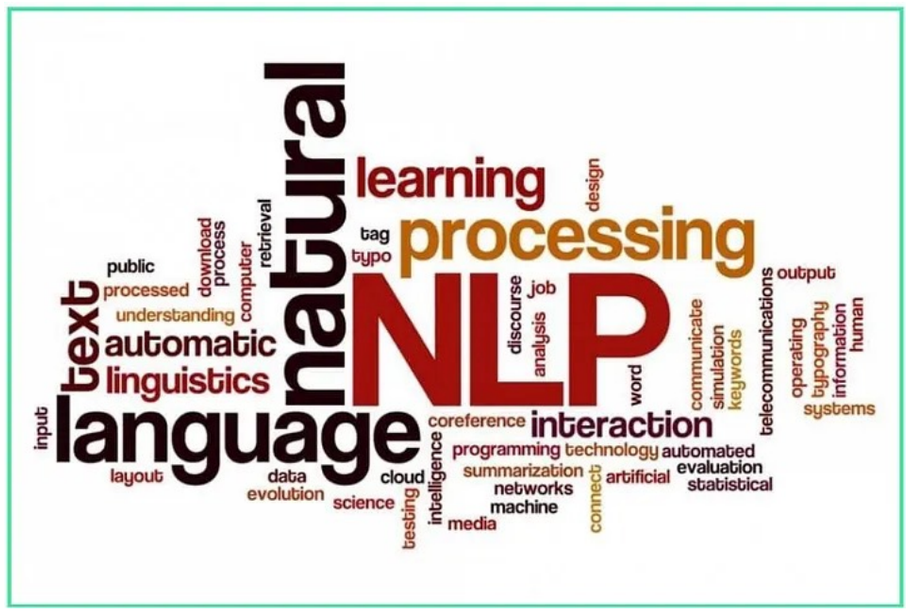


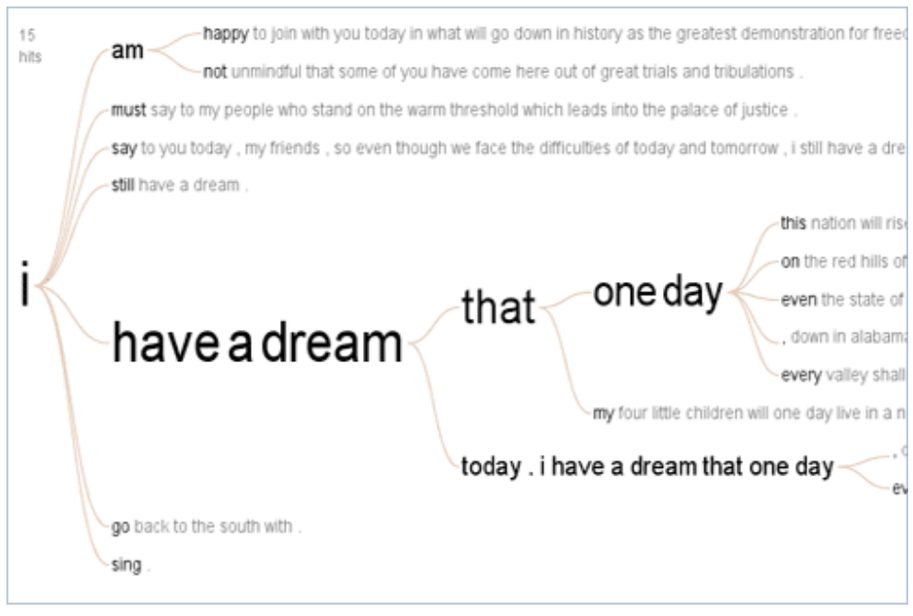


Librerías a instalar

Revisar que se tengan instaladas las siguientes librerías:

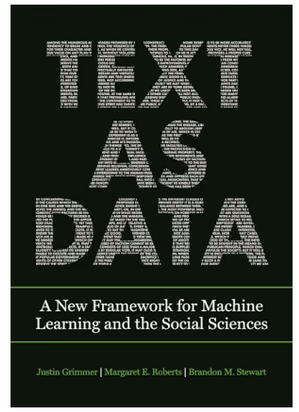
* **tm**
* **wordcloud2**
* **tidytext**
* **SnowballC**
* **udpipe**
* **ellmer**





Conceptos básicos de análisis de texto

Etapas del análisis de texto





Descubrimiento

Etapa inicial. se decide qué se quiere medir a partir de los datos y cuál será el objetivo de la inferencia



Organización

Estructura o esquema de clasificación que se aplica a un conjunto de documentos de texto para agruparlos, ordenarlos o describirlos de forma sistemática



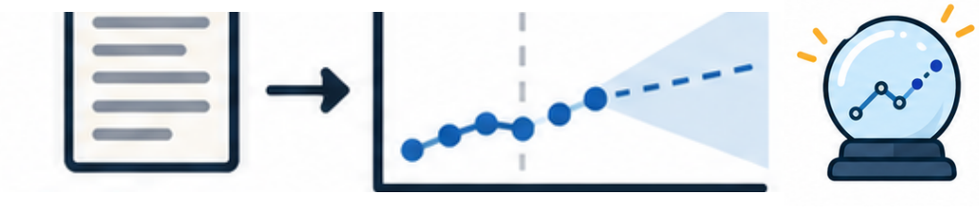
Medición

Crear una simplificación del fenómeno del mundo real que permita al analista describir con precisión un proceso o probar las implicaciones observables de una teoría. **Medir pues, contar palabras, usar Machine Learning. Meterle código.**



Inferencia causal

Determinar cómo cambiarían los resultados si se interviniera en el mundo. La meta es estimar lo que **habría sucedido** en un escenario contrafactual (no observado) si la intervención de interés hubiera sido diferente.



Predicción

La **predicción** es **la tarea de estimar el valor de un resultado para una unidad que se encuentra fuera de la población utilizada para entrenar el modelo.** El objetivo es pronosticar lo que sucederá en el futuro, o lo que está sucediendo ahora (nowcasting), utilizando la información disponible en el presente.

Usando el texto como evidencia

Método	Pregunta que responde
Clasificación supervisada	¿A qué categoría pertenece cada texto?
Temas (LDA y otros)	¿De qué se habla y con qué peso?
Frecuencias y diccionarios	¿Qué palabras distinguen a un corpus de otro?
Modelos de lenguaje (LLM)	¿Puede un modelo etiquetar como una persona experta?

Ejemplos de análisis de texto

Sentimiento en Twitter sobre el TLCAN

PREGUNTA

¿Se puede medir, casi en tiempo real, el ánimo público sobre una negociación comercial?

CORPUS Y MÉTODO

Unos 5 mil tuits con #TLCAN (abril y mayo de 2018), etiquetados a mano como positivos, negativos o neutros. Siete clasificadores y un «votador» que los combina.

HALLAZGO

Cada modelo por separado acierta entre 65% y 71%. El votador reporta 88%, pero solo clasifica los tuits en los que al menos 70% de los modelos coincide.

Aguilar, Sidorov y Batyrshin (2018), Research in Computing Science 147(5), 357–365.

Ejemplos de análisis de texto

Narrativa del Banco de México y expectativas

PREGUNTA

¿Los analistas reaccionan solo a los pronósticos numéricos de Banxico o también al tono de lo que escribe?

CORPUS Y MÉTODO

Resúmenes de los Informes Trimestrales de 2008 a 2021. LDA con 26 temas, número fijado por los autores; el tono de cada tema entra a una regresión.

HALLAZGO

Los analistas incorporan cerca de 25% de su diferencia con el pronóstico de inflación de Banxico. El tono del texto influye además de las cifras.

Antón, A., Bazdresch, S., & Lelo de Larrea, A. (2023). *Influencia de las proyecciones del banco central y la narrativa económica sobre las expectativas de los pronosticadores profesionales: Evidencia de México* (Documento de investigación del Banco de México No. 2023-21). Banco de México. https://www.banxico.org.mx/publicaciones-y-prensa/documentos-de-investigacion-del-banco-de-mexico/resumenes-ejecutivos/%7BC561B5CD-1917-E6BD-FD36-1E9A47B96543%7D.pdf

Ejemplos de análisis de texto

Tres planes de estudio de educación básica

PREGUNTA

¿Qué cambió en el discurso educativo entre el Plan 2011, Aprendizajes Clave 2017 y el Marco Curricular 2022?

CORPUS Y MÉTODO

Los tres documentos oficiales como corpus. Minería de texto en R (quanteda, tidyverse, word2vec), con métodos supervisados y no supervisados.

HALLAZGO

2011 enfatiza la disciplina; 2017, las competencias y la eficiencia; 2022, la comunidad, la inclusión y el bienestar de poblaciones vulnerables.

Duarte., Universidad Vasco de Quiroga. Consultado en Dialnet.

Ejemplos de análisis de texto

Mañaneras y aprobación presidencial

PREGUNTA

¿Lo que el presidente elige decir cada mañana mueve su propia aprobación?

CORPUS Y MÉTODO

1,385 conferencias de López Obrador. Minería de texto para medir cuánto se habla de cada tema; regresión dinámica con economía, seguridad y medios.

HALLAZGO

Cuanto más espacio ocupa la corrupción en las mañaneras, menor es la aprobación; el efecto es estadísticamente significativo.

Montalvo-Vásquez, Saldaña y Montero Bagatella (2025), Revista Mexicana de Opinión Pública (39), 43–78.

De López Obrador a Sheinbaum, en palabras

PREGUNTA

¿Qué continúa y qué se rompe en la narrativa presidencial cuando cambia quien la pronuncia?

CORPUS Y MÉTODO

19 documentos por presidente: el último mes de mañaneras de AMLO y el primero de Sheinbaum. Frecuencias en Voyant Tools, más lectura cercana.

HALLAZGO

«Pueblo»: 402 menciones contra 238. «Adversarios», «enemigos» y «conservadores»: 107 contra 8. El proyecto continúa con menos antagonismo.

Rivera Magos y González Pureco (2026), Global Media Journal México 23(45), 1–26.

Ejemplos de análisis de texto

INEGI: de la respuesta abierta al código

PREGUNTA

¿Puede un modelo asignar la clave de ocupación y de actividad económica a lo que cada persona responde con sus propias palabras?

CORPUS Y MÉTODO

158,568 registros de la ENIGH 2018 ya codificados por personas. TF-IDF de n-gramas y un ensamble de clasificadores; 461 ocupaciones y 157 actividades.

HALLAZGO

Acierta 85% en ocupación y 89% en actividad: permitiría automatizar la mitad de lo que se codifica a mano. En 2024 el INEGI ya probaba BERT.

Ruiz Sánchez, Pérez Sánchez y López Monroy (2022), Realidad, Datos y Espacio 13(2); Pimentel (2024).

Ejemplos de análisis de texto

Datos contra el feminicidio

PREGUNTA

Cuando el registro oficial es incompleto, ¿puede la prensa servir de fuente para documentar feminicidios?

CORPUS Y MÉTODO

Notas periodísticas. Un clasificador diseñado junto con activistas filtra las relevantes, agrupa las que tratan el mismo caso y envía alertas por correo.

HALLAZGO

En 2022 lo usaban 26 organizaciones, que reportaban encontrar casos que antes no veían. El modelo filtra; las personas deciden y registran.

Bhargava et al. (2022), Computation + Journalism. Proyecto de D’Ignazio, Fumega y Suárez Val.

Ejemplos de análisis de texto

ChatGPT frente a anotadores humanos

PREGUNTA

¿Puede un modelo de lenguaje etiquetar textos con el mismo libro de códigos que usan los asistentes de investigación?

CORPUS Y MÉTODO

6,183 tuits y notas de prensa. Relevancia, postura, temas y encuadres, sin ejemplos previos (zero-shot), comparado con trabajadores de MTurk.

HALLAZGO

Supera a MTurk por unos 25 puntos porcentuales de exactitud y cuesta menos de 0.003 dólares por anotación, unas treinta veces menos.

Gilardi, Alizadeh y Kubli (2023), PNAS 120(30), e2305016120.

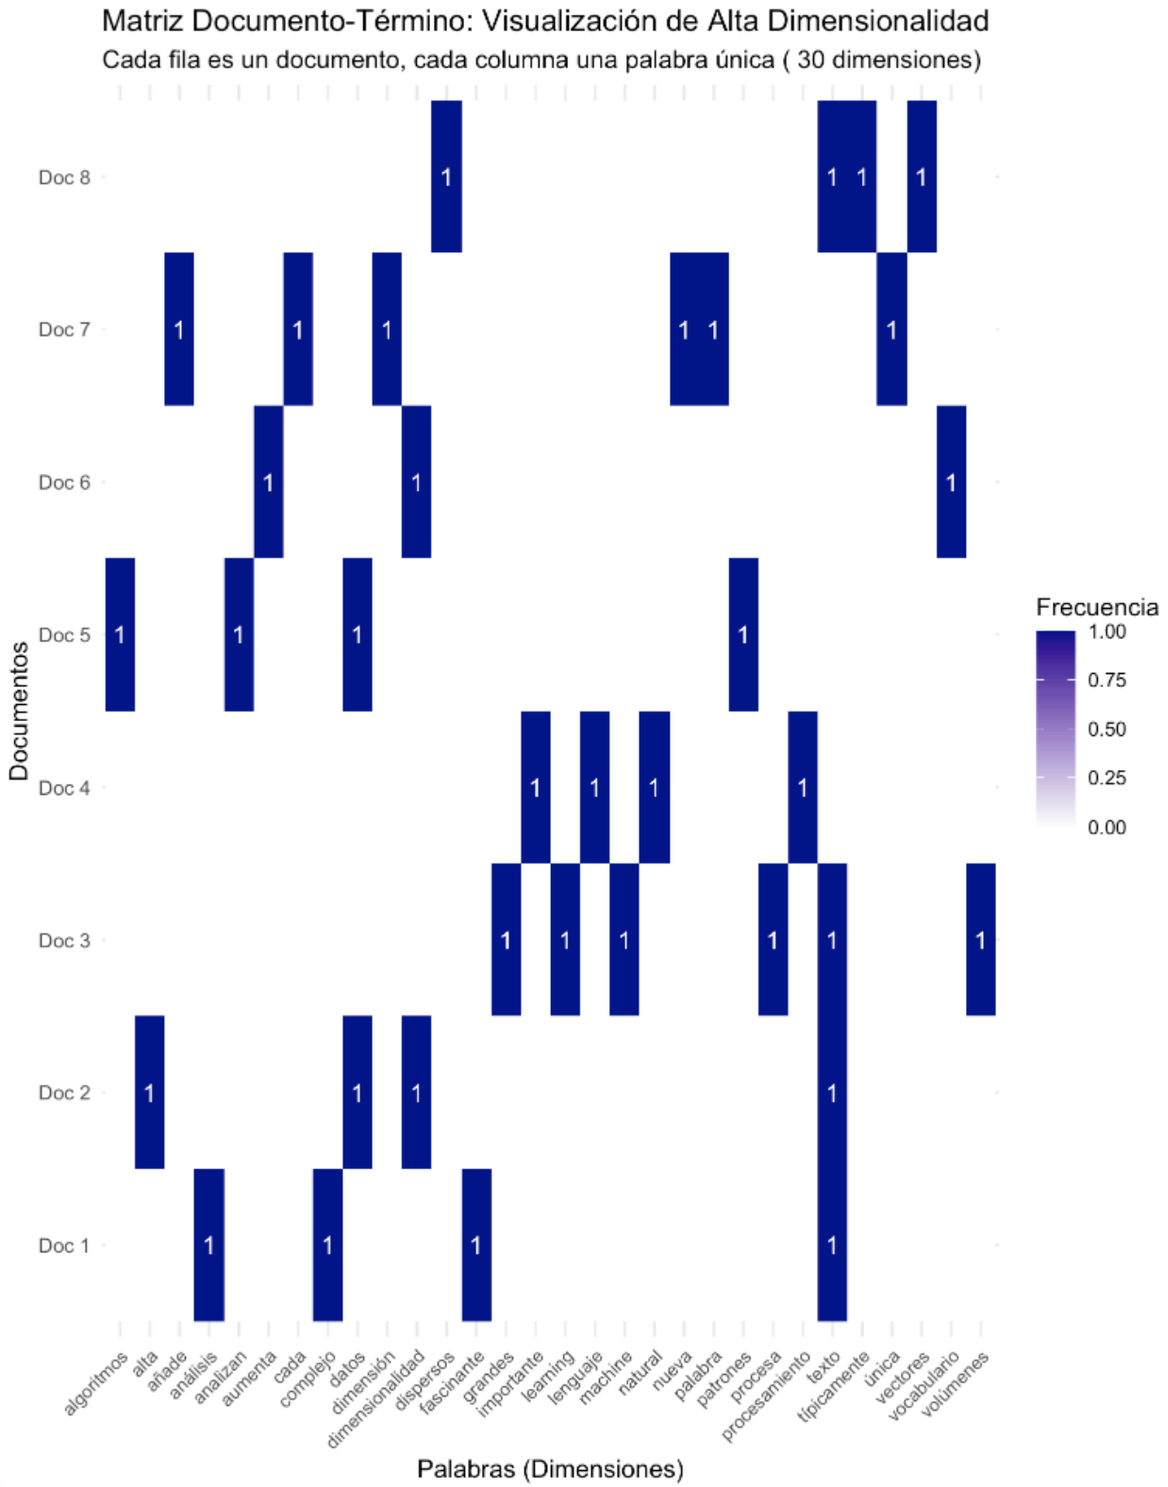
Preprocesamiento

Preprocesamiento

⭐ **Definición: Convertir** el lenguaje natural **en un conjunto de representaciones más limpias y manejables**, que los algoritmos puedan interpretar mejor para descubrir patrones, temas o sentimientos.



¿Por qué es necesario?



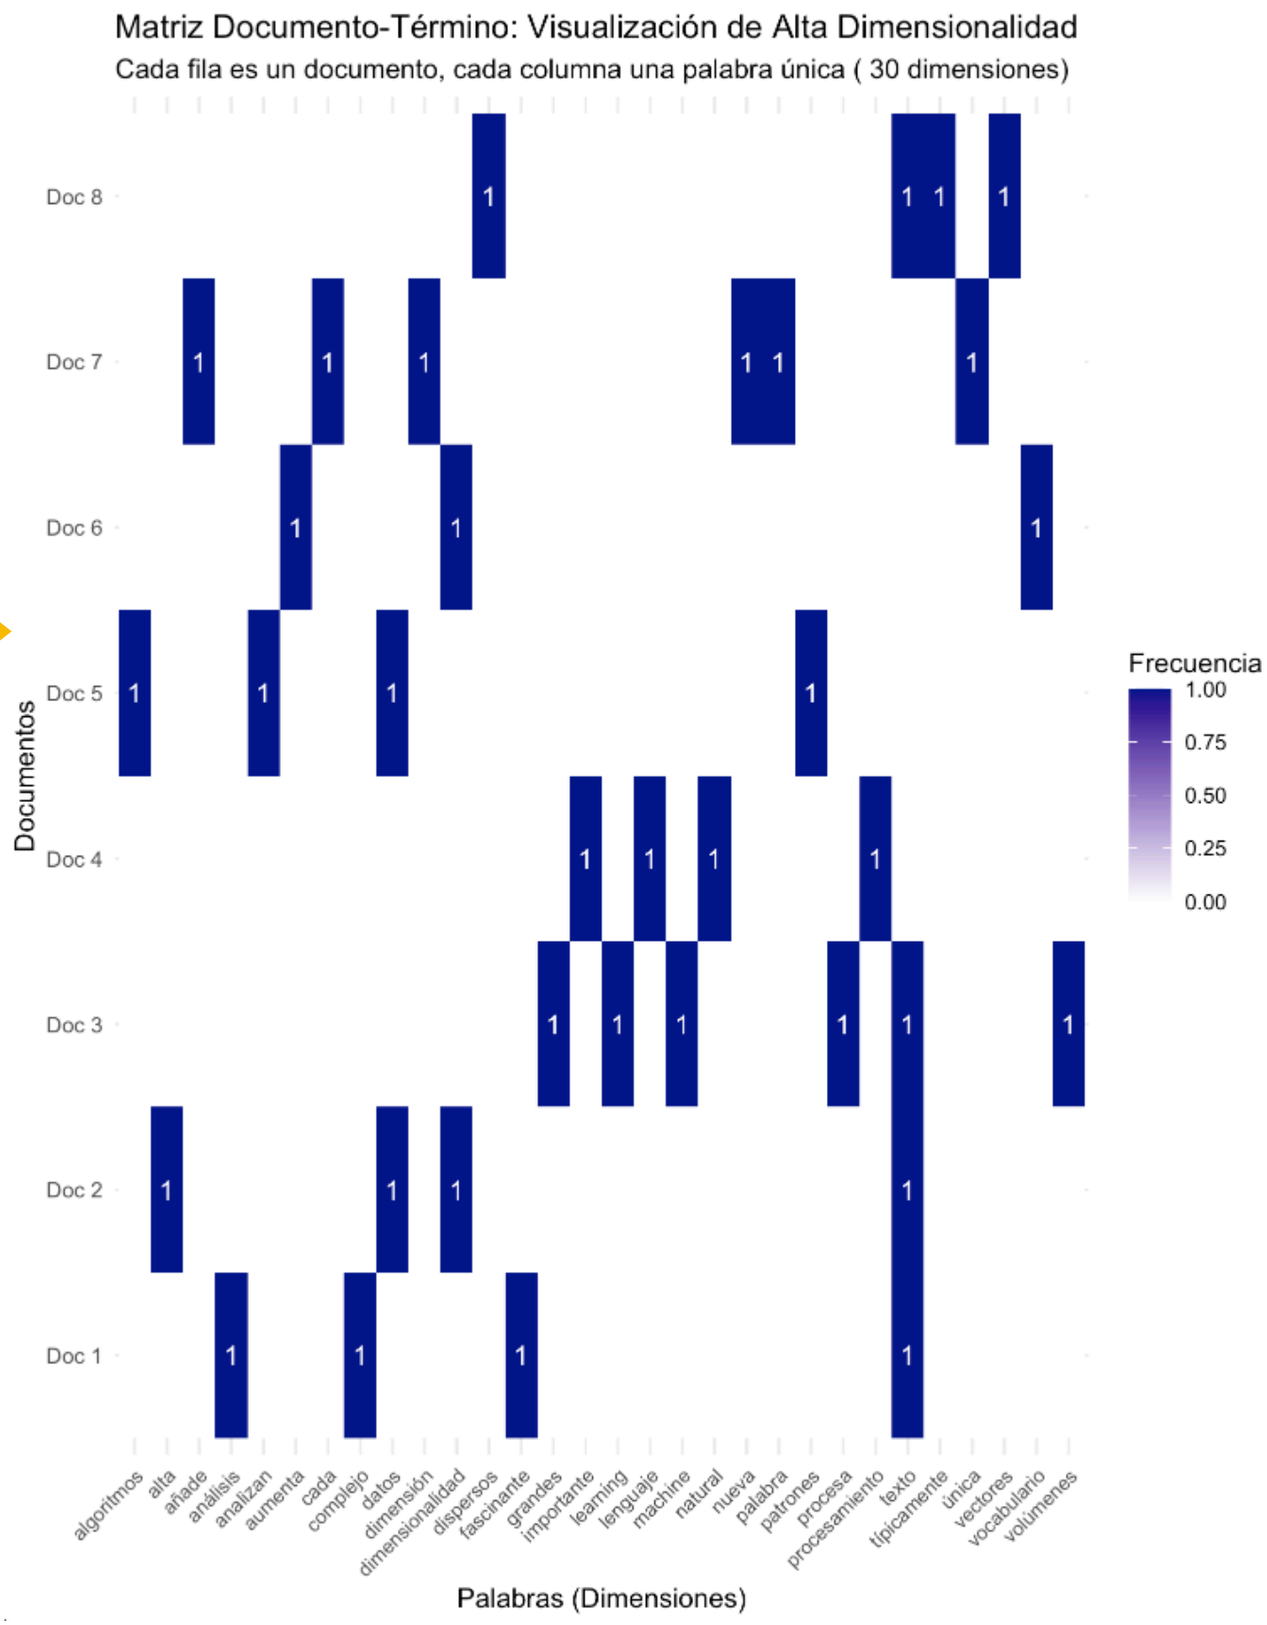
El preprocesamiento nos ayuda con el problema de **la alta dimensionalidad de los textos** y la **redundancia de palabras.**

¿Alta dimensionalidad?

```r
# Cargar librerías necesarias
library(tm)         # Para procesamiento de texto
library(Matrix)     # Para matrices dispersas
library(ggplot2)    # Para visualizaciones
library(tidyr)      # Para manipulación de datos

# Configurar semilla para reproducibilidad
set.seed(123)
# 1. CREAR UN CORPUS DE EJEMPLO
# -----------------------------
documentos <- c(
  "El análisis de texto es fascinante y complejo",
  "Los datos de texto tienen alta dimensionalidad",
  "Machine learning procesa grandes volúmenes de texto",
  "El procesamiento del lenguaje natural es importante",
  "Los algoritmos analizan patrones en los datos",
  "La dimensionalidad aumenta con el vocabulario",
  "Cada palabra única añade una nueva dimensión",
  "Los vectores de texto son típicamente dispersos"
)

corpus <- Corpus(VectorSource(documentos))
corpus <- tm_map(corpus, content_transformer(tolower))
corpus <- tm_map(corpus, removePunctuation)
corpus <- tm_map(corpus, removeWords, stopwords("spanish"))
corpus <- tm_map(corpus, stripWhitespace)
```



Problemas que ataca el preprocesamiento

1 Reducir la dimensionalidad

Menos palabras ⇒ menos dimensiones.



2 Evitar la redundancia

Eliminar o unificar palabras que aportan el mismo significado.



3 Mejorar la señal semántica

Que los conteos, frecuencias, TF-IDF, embeddings o modelos de Machine Learning **se basen en características relevantes.**



4 Hacer más eficientes y robustos los algoritmos de análisis de textos.



Conceptos de preprocesamiento

Token: (*en este contexto*) Un token es una unidad de lenguaje, como una palabra o una frase, que se cuenta o que se analiza.

Por ejemplo, en la frase "Good night, good night!" el *token* "good" aparece dos veces y "night" también.

Ejemplos de tokens:

* Frases
* Palabras
* *Ngramas*
* Letras/caracteres
* Ocurrencia de expresiones regulares

Tokenización: Es el proceso de dividir un texto en unidades más pequeñas llamadas *tokens*.

Comúnmente, cada token es una palabra, pero según la necesidad también podemos tokenizar con oraciones, caracteres individuales o incluso sub-palabras.

Por ejemplo, al tokenizar *"Hola mundo, ¿cómo estás?"* podríamos obtener los tokens: ["Hola", "mundo", ",", "¿", "cómo", "estás", "?"].

Conceptos de preprocesamiento

Vocabulario: Un vocabulario es un conjunto que contiene todos los tokens únicos que existen en todo el conjunto de datos con los que vamos a trabajar (base de entrenamiento, de prueba, de validación, etc).

$$V = \{palabra_1, palabra_2, \ldots, palabra_N\}$$

Es como un catálogo de productos; el vocabulario tiene todos los productos disponibles.

Documento y corpus:

⭐ **Documento**: El documento es la unidad fundamental de análisis de texto.

Puede ser cualquier cosa, desde un único mensaje de Twitter hasta un informe anual de una empresa o un discurso de un político.

La forma de definir un documento depende del objetivo de la investigación. Por ejemplo, para la detección de spam, un documento podría ser un correo electrónico individual. Para el análisis de precios de acciones a partir de noticias, un documento podría ser el texto de las noticias de un día en particular.

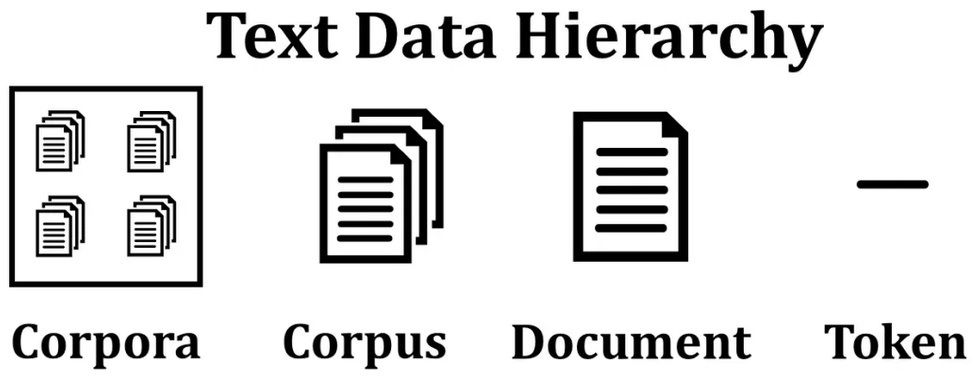
⭐ **Corpus**: Un corpus es una colección de documentos. Es el conjunto de texto que se va a analizar.

Documento:



Corpus:





Bolsa de palabras

⭐ **Bolsa de palabras**: método simple y de conteo que **transforma un texto en un vector numérico a través del conteo de palabras**, sin tener en cuenta el orden ni la gramática de dichas palabras.



- Forma de representar texto
- Se construye un bolsón con todas las palabras que aparecen en el *corpus*
- Se ignora el orden de las palabras; solo importa la frecuencia
- Es sencillo y fácil de construir
- Base de muchos modelos de NLP: clasificación de textos, detección de spam, etc.

Stopwords

⭐ **Stopwords**: son aquellas palabras que son **estructurales del idioma** y que conectan o forman las frases, pero que no aportan significado temático clave para distinguir el tema principal de un texto.

El, la los las, un, una, de, a, en, con , por, para, sobre, y, o, pero, que, es, están, son, esta… etc.

Las stopwords se eliminan por dos objetivos principales:

Reducir el Ruido y la Dimensionalidad: Al eliminar miles de palabras que significan poco, se reduce drásticamente el tamaño del **vocabulario** y, por lo tanto, el tamaño de los vectores. Esto hace que los modelos de Machine Learning sean más rápidos de entrenar y menos propensos al sobreajuste.

Enfocarse en el Núcleo Temático: Al quitar palabras como “el", "de", "un", "es", etc., el modelo se ve obligado a prestar atención a palabras clave del texto, como "perro", "ciencia", "economía", que son las que realmente definen el tema del texto.

⭐Lematización.

Técnica para **reducir las palabras a su forma base o *lema***, que es la forma en la que las encontraríamos en el diccionario.

A diferencia de simplemente recortar terminaciones, l**a lematización utiliza reglas lingüísticas** (y a veces diccionarios) **para mapear, por ejemplo, un verbo conjugado a su infinitivo, o un sustantivo plural a su singular**. Por ello, *corriendo*, *corrí* y *corre* se lematizarían todas como *"correr"*.

Ejemplo: Un *lematizador* procesando la frase

"Los niños **jugaban** en los parques"

transformaría:

"*jugaban*" -> "*jugar*" y "*parques*" -> "*parque*".

⭐ Stemming

Proceso que también **reduce las palabras a una raíz común**, pero **utilizando métodos más simples y mecánicos que la lematización.**

En esencia, un algoritmo *stemmer* corta prefijos o sufijos de las palabras para eliminar *morfemas flexivos**. Por ejemplo, aplicando stemming en inglés: *"connections", "connected", "connecting"* todas podrían truncarse al stem *"connect"*; en español, "*jugar*", "*jugando*", "*jugarán*" podrían reducirse a "*jug*" o "*juga*".

La raíz obtenida no siempre es una palabra completa con significado (a veces son fragmentos), pero suele bastar para agrupar textos que hablan de lo mismo. El stemming es rápido y útil para reducir dimensionalidad (menos formas distintas), aunque sacrifica precisión porque no distingue contextos ni excepciones gramaticales.

***Ejemplo**:* Con un **Porter stemmer** (algoritmo clásico de stemming), las palabras *"corriendo"*, *"corre"* y *"corrí"* se recortan todas a *"corr"*.

* Los **morfemas flexivos** son las **terminaciones** que se añaden a una palabra para expresar rasgos **gramaticales** (sin crear una palabra nueva). Señalan cosas como **género** y **número** en sustantivos/adjetivos, y **persona, número, tiempo, modo y aspecto** en verbos.

⭐ *n-gramas*

- Secuencia contígua de n-elementos dentro de una muestra de texto
- Capturan el *contexto local* dentro de una oración o documento

Tipo de N-grama	Secuencias (Ejemplo de salida)
Unigramas ($n = 1$)	"La", "inteligencia", "artificial", "es", "fascinante"
Bigramas ($n = 2$)	"La inteligencia", "inteligencia artificial", "artificial es", "es fascinante"
Trigramas ($n = 3$)	"La inteligencia artificial", "inteligencia artificial es", "artificial es fascinante"

{tidytext}



La librería **tidytext** en R es un paquete diseñado para facilitar el **análisis de texto** siguiendo la filosofía del *tidyverse*(datos organizados en formato de tabla, donde cada fila es una observación y cada columna es una variable).

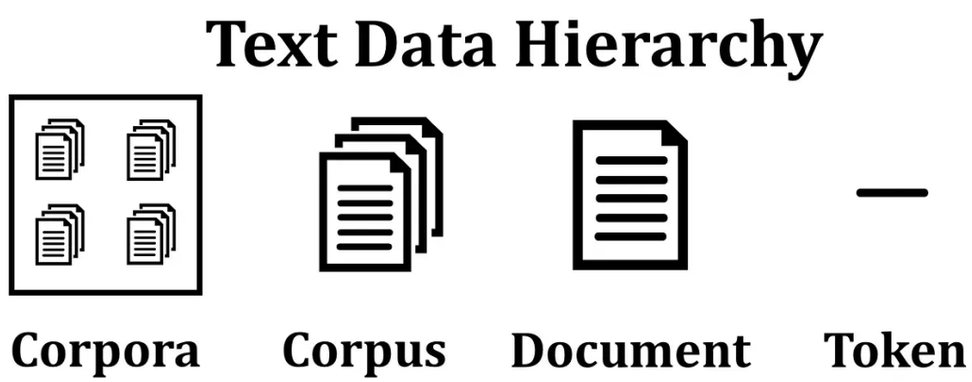
tidytext **convierte texto no estructurado en datos ordenados**, listos para ser analizados con todas las herramientas del *tidyverse*. Es ideal para quien quiera hacer minería de texto en R sin necesidad de usar estructuras más rígidas como los corpus de tm.

Tokenizando texto:



Algo de vocabulario de procesamiento de lenguaje natural (NLP):

- **Bolsa de palabras** (*Bag of words*): Las palabras en un documento son independientes
- Cada cuerpo de texto separado es un ***documento***
- Cada palabra única es un ***término***
- Cada ocurrencia de un *término* es un ***token***
- Crear una bolsa de palabras se hace mediante ***tokenización***



tidytext::unnest_tokens()




```
mananera_reciente %>%
  unnest_tokens(output = "palabras", input = texto,
                token = "words", to_lower = T)
```

```
# A tibble: 14,743 × 3
   titulo                                                                                                fecha                 palabras
   <chr>                                                                                                 <chr>                 <chr>
 1 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 presidenta
 2 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 de
 3 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 mexico
 4 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 claudia
 5 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 sheinbaum
 6 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 pardo
 7 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 buenos
 8 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 dias
 9 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 como
10 Conferencia de prensa de la presidenta Claudia Sheinbaum Pardo del 24 de septiembre de 2025 24 de septiembre de 2025 estan
# ℹ 14,733 more rows
# ℹ Use `print(n = ...)` to see more rows
```

Contar palabras




```
mananera_reciente %>%
  unnest_tokens(output = "palabras", input = texto,
                token = "words", to_lower = T) %>%
  group_by(palabras) %>%
  count() %>%
  arrange(-n)
```

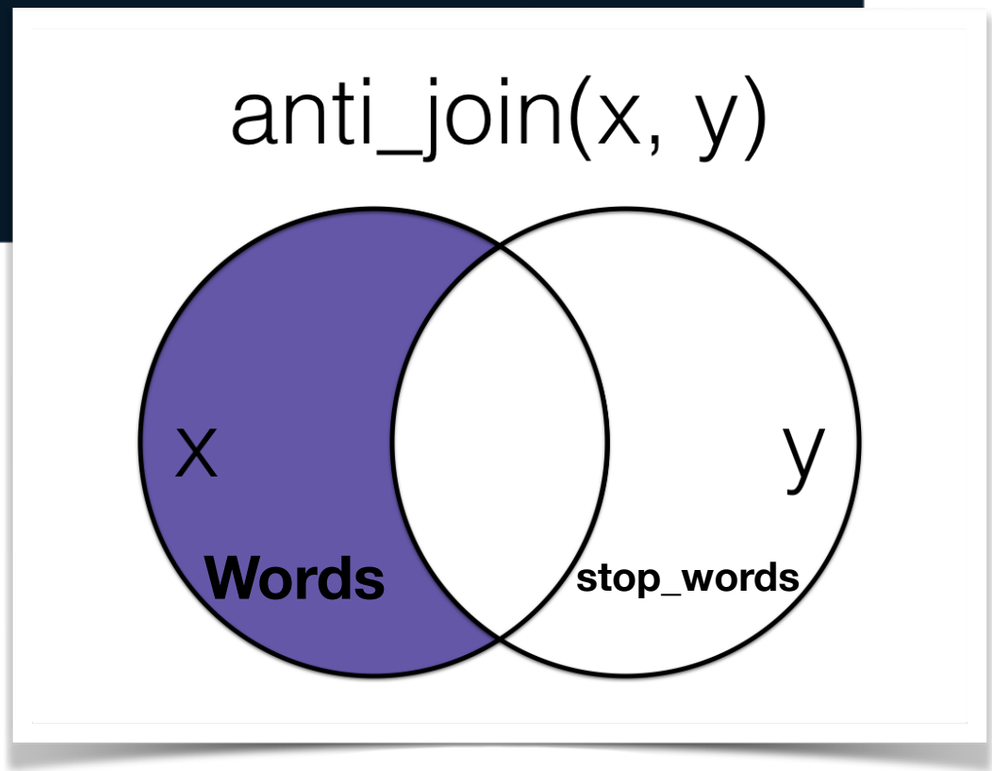
```
# A tibble: 2,564 × 2
# Groups:   palabras [2,564]
   palabras     n
   <chr>    <int>
 1 de         876
 2 que        712
 3 la         454
 4 en         354
 5 y          343
 6 el         341
 7 a          338
 8 se         324
 9 es         219
10 un         179
# ℹ 2,554 more rows
```

anti_join()




```
tidy_review2 <- review_data %>%
  unnest_tokens(word, review) %>%
  anti_join(stop_words)
tidy_review2
```

```
# A tibble: 78,868 x 4
   date      product                          stars word
   <chr>     <chr>                            <dbl> <chr>
 1 1/12/15   iRobot Roomba 650 for Pets           4 walk
 2 1/12/15   iRobot Roomba 650 for Pets           4 rest
# … with 78,866 more rows
```



SnowballC

La librería **SnowballC** en R es una implementación del algoritmo de **stemming (reducción de palabras a su raíz)** de Snowball, desarrollado por Martin Porter.

Su función principal es **reducir las palabras a su forma base o raíz (stem)**.

Ejemplos:

- "corriendo", "correr", "corredor" → "corr"
- "casas", "casita", "casero" → "cas"
- "computadora", "computadoras", "computar" → "comput"

Actividad práctica

1. Cargue el excel que contiene el texto de las mañaneras de la presidenta, el cual se encuentra en la carpeta “01_datos/estenograficas_sheinbaum.xlsx”.
    1. Genere un objeto con el contenido de la mañanera más reciente, y guardelo en el objeto *mananera_reciente*
    2. Para el objeto *mananera_reciente*, realice las siguientes actividades:
        1. Elimine todos los acentos
        2. Elimine todos los números

3. Descomponga el texto en *tokens* de *frases.*

4. Descomponga el texto en *tokens* de ngramas (3,4 y 5).

4. Descomponga el texto en *tokens* de *palabras.* Realice un wordcloud con estas palabras. Guarde este resultado en un objeto llamado “palabras”

5. Realice un *wordcloud* con los *ngramas*

6. Elimine las *stopwords* del objeto *palabras*

Actividad práctica

7. Obtenga el stemming y los lemas de las palabras de la mañanera más reciente. Guarde estos en columnas adicionales del texto

8. Verifique el total de palabras que hay en la columna de palabras, en la columna de términos con el stemming y con la lematización. ¿Cual columna tiene el vocabulario más pequeño?

9. Cuente las palabras más utilizadas en la primera mañanera. Quédese con las primeras 10 en términos de frecuencia.

10. Realice este procedimiento en bucle para el resto de las conferencias.

11. Una vez que tiene las diez palabras más populares de todas las mañaneras, realice un wordcloud con estas palabras.

12. Utilizando zero-shot prompting, trate de determinar de que trató cada conferencia mañanera. Agrupe las mañaneras con temas similares.